

ANALYSE FACTORIELLE DES DONNÉES

SUPPORT DE COURS

Par OGOUMEDI Obidon

E-mail : obidonogoumedi@yahoo.com

Inspiré de :

KEHO Yaya, Analyse factorielle des données, Note pédagogique,
décembre 2004 Statistiques et Analyse des Données, Note pédagogique,
janvier 2005 (ENSEA, Abidjan)

Chap. I. INTRODUCTION GENERALE

Ce chapitre a pour objet de présenter les besoins de données dans la vie courante, et le nécessaire recourt aux méthodes d'analyse multidimensionnelle.

1.1. Place de l'Analyse des Données et des Méthodes Statistiques dans la vie courante

La place des données dans la vie d'un pays, d'une entreprise ou d'un individu est incontestable. En effet, toute activité de production, de vente, d'achat, de planification, de prévision, ou toute décision requiert un certain nombre d'informations. Les données servent justement à obtenir des informations et l'information aide à décider ou agir rationnellement. Plusieurs exemples peuvent être choisis à titre illustratifs.

- i) Le laborantin analysera les indications (données) sur un prélèvement afin de déterminer une pathologie ;
- ii) Le médecin analysera les données (symptômes) recueillies sur un patient pour établir son diagnostic et prescrire un traitement ;
- iii) Le qualiticien analysera les caractéristiques d'un produit pour le tester et envisager un plan d'amélioration de la qualité.
- iv) Le gestionnaire analysera les données comptables (CA, masse salariale, autres charges, ...) et, en fonction de la conjoncture, modifiera si nécessaire sa politique salariale, ses stratégies commerciales et de production.

En bref, les données sont au cœur du processus de décision. Seulement, pour partir des données et tirer des informations adéquates pour décider il faut de la méthode. C'est ce qui justifie l'intérêt d'étudier des méthodes d'analyse des données permettant de synthétiser efficacement les aspects structurels significatifs des faits, traduits en termes de données, et d'établir des relations pertinentes entre ces faits. Ces méthodes permettent de construire des indicateurs clés qui aident à la compréhension de ces faits et à la prise de décisions.

NOTE : En aval de la phase de traitement et d'analyse des données se situe une phase de recueil des données qui est déterminante, délicate, et même la plus importante. En effet, une excellente analyse effectuée sur des données fausses n'a évidemment aucune valeur, car elle conduit à des résultats erronés et donc à des mauvaises décisions. La phase de recueil des données doit donc être faite avec le plus grand soin afin d'obtenir des données justes, vraies et précises desquelles on pourra tirer des résultats valables.

Ce cours se limite à la présentation des techniques de description et d'exploitation des données multidimensionnelles et à l'utilisation d'outils informatiques appropriés.

1.2. De la Statistique Univariée et bivariée à la statistique descriptive multidimensionnelle

L'étude séparée des variables (une à une ou deux à deux) est riche et indispensable. Elle permet globalement de déceler les tendances, les dispersions, les répartitions et même les liaisons entre deux variables.

Toutefois, dans la plupart des études de la vie courante, on dispose d'un (vaste) ensemble d'individus statistiques et des variables en nombre élevé (10, 20, 50 et plus). On souhaiterait faire ressortir les liaisons multiples entre ces variables, et qui constituent l'aspect le plus important d'une analyse des données.

Par exemple, dans une enquête d'opinion sur un produit, il serait instructif de mettre en relations les appréciations des consommateurs (prix, goût, aspect, forme parfum, ...) avec certaines caractéristiques de ceux-ci (revenu, âge, sexe, religion, catégorie socioprofessionnelle, ...). L'analyse descriptive univariée, malgré sa pertinence, ne permet pas de répondre à ce besoin. Et c'est là qu'interviennent les méthodes d'analyse des données multidimensionnelles.

L'intérêt principal de ces méthodes est d'analyser les données en tenant compte de leur caractère multidimensionnel. Elles fournissent un résumé descriptif d'un vaste ensemble de données

à partir de représentations graphiques. Ces représentations permettent de déceler les aspects structurels importants tels que les ressemblances, les liaisons, les combinaisons que de simples calculs ne sauraient mettre en évidence. Ces méthodes permettent encore de décrire, soit une variable à partir de plusieurs autres, soit les différences entre des individus à partir des variables qui les décrivent.

Remarque : Les méthodes d'analyse des données sont *descriptives* et non *explicatives*. Elles ne sauraient donc être utilisées pour déduire des lois (comme des causalités). Elles peuvent à la limite aider à la formulation d'hypothèses.

1.3. Les Différentes Méthodes d'Analyse des Données Multidimensionnelles

Les méthodes d'analyse des données sont diverses, et dépendent, d'abord, de la nature des données disponibles, ensuite dans une certaine mesure de l'objectif recherché.

En statistique, on distingue deux types de données ou de variables suivant la nature des valeurs possibles : les variables quantitatives et les variables (ou caractères) qualitatives (qualitatifs).

Les variables quantitatives sont celles qui sont mesurables par un nombre. C'est le cas du revenu, de l'âge, du CA, du PIB, Ce type de variables se prête aux calculs statistiques tels que la moyenne ou la variance.

Les caractères (variables) qui sont non mesurables sont dits(es) qualitatifs (ves). Les valeurs prises par ces caractères sont appelées modalités et ne se prêtent pas aux calculs statistiques tels que la moyenne. C'est le cas du sexe ou de la catégorie socioprofessionnelle. On voit que le type d'analyse dépend du type de données.

Il existe trois méthodes fondamentales en analyse factorielle :

- i) La méthode dite ACP (**A**nalyse en **C**omposantes **P**incipales) qui convient lorsque les variables déterminantes (ou clés ou d'intérêt ou encore *actives*¹) sont quantitatives. On peut toutefois y introduire des variables qualitatives (et même d'autres variables quantitatives) à titre illustratif ;
- ii) La méthode dite AFC (**A**nalyse **F**actorielle des **C**orrespondances **s**imples) qui s'utilise lorsque l'on s'intéresse aux correspondances entre deux variables qualitatives. Cette méthode permet en outre d'analyser la liaison entre deux caractères qualitatifs (par un test du χ^2).
- iii) La méthode dite ACM (**A**nalyse **f**actorielle des **C**orrespondances **M**ultiples) qui est adaptée lorsqu'on étudie les correspondances entre plus de deux variables qualitatives. Comme dans le cas de l'ACP, il est possible d'y introduire des variables quantitatives (et même d'autres variables qualitatives) à titre illustratif ;

Ces trois méthodes descriptives peuvent être complétées par une classification qui permet de répartir les individus en groupes homogènes.

Sur le plan théorique, l'ACP est la méthode de base de l'analyse factorielle, car sa compréhension facilite celle des autres méthodes. Mais sur un plan pratique, l'ACM présente un grand intérêt et des performances supérieures. Puisqu'elle permet d'analyser un tableau de données de toutes natures. Il suffira seulement de faire des regroupements en classes pour chaque variable quantitative à prendre en compte dans l'analyse et elles pourront alors être utilisées comme des variables qualitatives.

L'analyse des résultats et leur interprétation nécessite aussi une bonne connaissance du contexte d'étude et du sens des variables. Cette connaissance nous aidera par ailleurs dans le choix des méthodes et dans la sélection des variables à introduire (parmi un vaste ensemble de variables). Il convient donc de toujours se poser les questions suivantes :

- Pourquoi les données ont-elles été collectées ?
- Quelle est la nature de celles-ci ?
- Qui sont les individus statistiques ?

¹ Ce terme sera défini plus loin.

- Quelle(s) méthode(s) pertinente(s) pour ces données ?

Pour toutes les applications informatiques, nous utiliserons le logiciel Spad, qui est le logiciel par excellence de l'analyse des données. On peut toutefois aussi utiliser Stata, et même quelque peu SPSS.

A la fin du cours, l'étudiant doit être à mesure de savoir traduire une problématique, en identifiant la technique appropriée, et en l'appliquant (à l'aide de l'outil informatique). Il doit en outre savoir interpréter les résultats.

Chap. II. ANALYSE FACTORIELLE D'UN NUAGE DE POINTS

Ce chapitre présente les outils géométriques d'aide à la compréhension de la méthodologie générale des analyses factorielles, et les éléments d'interprétation des résultats. Certains des éléments présentés dans ce chapitre sont propres à l'ACP. Ce qui se justifie, puisque, comme déjà signalé, c'est la méthode de base. **Nous présentons ici une analyse dite normée.**

II.1. Définitions Générales

Au départ, nous disposons de données statistiques : une population de N individus décrits par P variables quantitatives (actives²). Le tableau de données correspondantes est donné par la matrice rectangulaire X suivante.

	Variables					
Individus		X_1	...	X_j	...	X_P
	1	X_{11}				X_{1P}
	i	X_{i1}		X_{ij}		X_{iP}
	N	X_{N1}		X_{Nj}		X_{NP}

Le terme générique X_{ij} représente la valeur numérique prise par l'individu « i » pour la variable « X_j ».

Note : Pour parvenir à des représentations (ce qui fait appel à la géométrie) nous devons adopter des considérations géométriques. Ce n'est qu'une question d'interprétation !

Ce tableau peut à la fois être vu comme un ensemble d'individus décrits par « P » valeurs (correspondant aux variables) ou comme un ensemble de variables décrites par N valeurs (correspondant aux individus).

a) Notions de point individu/variable et de nuage de points

L'individu de rang « i » peut être considéré comme un *point individu* noté e_i de l'espace R^P dont les coordonnées sont les valeurs $(x_{i1}, x_{i2}, \dots, x_{iP})$ prises sur les P variables. L'ensemble de tous les points individus, noté $\mathcal{X}(I)$ représente le nuage de points individus encore appelé nuage direct.

De façon duale, la variable X_j peut être considérée comme un *point variable* de l'espace R^N et l'ensemble de tous ces points variables, noté $\mathcal{X}(J)$ est le nuage des points variables appelé encore nuage dual.

b) Notion de masse d'un point

Dans un tableau de données, les points (individus ou variables) n'ont pas nécessairement la même importance. Dans certains cas, il peut exister une différenciation entre ces points : à chaque point individu e_i (ou variable X_j) il peut être associé un coefficient f_i (ou f^j) qui exprime l'importance du point dans le tableau. Ce coefficient de pondération est appelé poids ou masse du point.

Dans la pratique, cette « masse » peut se rapporter à un coefficient de pondération pour un relevé de notes, à la taille des ménages (nombre de personnes vivant dans le ménage) pour une base de données sur les ménages, à un coefficient d'extrapolation des individus d'un échantillon dans le cadre d'une enquête par exemple.

c) Ressemblance entre les points et liaison entre variables

Etant donné qu'on cherche à lire les ressemblances entre points sur des graphiques, il serait *naturel* que cela soit traduit par les proximités qu'il est possible de mesurer entre deux points individus/variables.

Entre deux individus (dans le nuage direct), on mesure la proximité à l'aide de la distance euclidienne. Pour deux points individus e_i et e_l , on a :

² Cette notion est définie en fin de chapitre en II.3. e.

$$d^2(e_i, e_l) = \|e_i - e_l\| = \sum_j^P (x_{ij} - x_{lj})^2 \quad (1)$$

Entre deux points variables (dans le nuage dual) l'association (ou liaison) se mesure à l'aide du coefficient de corrélation linéaire. Pour deux variables X_j et X_k , on a :

$$d^2(X_j, X_k) = \text{corr}(X_j, X_k) = \frac{\text{cov}(X_j, X_k)}{\sigma_j \sigma_k} \quad (2)$$

$$\text{avec } \text{cov}(X_j, X_k) = \frac{1}{N} \sum_{i=1}^N (x_{ij} - \bar{x}_j)(x_{ik} - \bar{x}_k) \quad (3)$$

$$\text{Rappelons que la moyenne d'une variable } X_j \text{ est } \bar{x}_j = \frac{1}{N} \sum_{i=1}^N x_{ij} \quad (4)$$

Nous verrons plus loin que ce coefficient n'est rien d'autre que le cosinus de l'angle formé par les deux vecteurs variables. Géométriquement, la corrélation renseigne sur l'angle formé par ces variables, considérés comme des vecteurs.

d) Notion de centre de gravité

Au nuage direct, on associe le centre de gravité g dont les coordonnées sont les moyennes des différentes variables :

$$g = \bar{e} = \frac{1}{N} \sum_{i=1}^N e_i = (\bar{x}_1, \bar{x}_2, \dots, \bar{x}_p) \quad (5)$$

g représente l'individu moyen

Remarque : Les formules (1) et (4) et (5) ne sont valables que lorsque les points ont des masses unitaires. Le cas contraire, ces coefficients interviennent dans les formules et les modifient quelque peu.

e) Notion d'inertie

L'inertie d'un nuage de points mesure la dispersion pondérée de ces points autour de son centre de gravité. Elle se définit par :

$$I_g = \frac{1}{N} \sum_{i=1}^N d^2(e_i, g) = \frac{1}{N} \sum_{i=1}^N \sum_{j=1}^P (x_{ij} - \bar{x}_j)^2 = \sum_{j=1}^P \sigma_j^2 \quad (6)$$

L'inertie est égale à la somme des variances de toutes les variables. On démontre ainsi que l'inertie correspond à la notion statistique de « variance ». L'inertie peut donc être comprise comme la dispersion (ou l'étalement) totale du nuage autour de son centre de gravité qui est l'individu moyen.

Puisque l'information à résumer dans le nuage de points se traduit par les proximités, soit la dispersion, l'inertie est donc la mesure de l'information totale contenue dans le nuage et que nous cherchons à traduire et à résumer.

f) Notions de variable centrée et de variable réduite

Centrer une variable X_j c'est simplement soustraire la moyenne de la variable de chaque valeur prise par un individu, c'est-à-dire faire la transformation : $\tilde{x}_{ij} = x_{ij} - \bar{x}_j$

Réduire une variable X_j c'est diviser chaque valeur prise par un individu pour la variable par l'écart type de la variable. Soit faire la transformation : $\tilde{x}_{ij} = x_{ij} / \sigma_j$

Lorsqu'une variable est à la fois centrée et réduite, chaque valeur est transformée par la formule suivante : $x_{ij}^* = (x_{ij} - \bar{x}_j) / \sigma_j$

g) Remarques et propriétés

Dans la pratique, il est souvent préférable de travailler sur des données indépendantes des unités de mesure et des échelles de grandeurs. Ceci afin de s'affranchir de leurs influences dans les calculs. Cela se résout en considérant les variables centrées et réduites plutôt que les variables brutes. Le fait de centrer et/ou réduire une variable apporte quelques simplifications intéressantes :

- i) La moyenne d'une variable centrée est nulle. Par conséquent, lorsque toutes les variables sont centrées, le centre de gravité (qui est l'individu moyen) se confond avec l'origine : $g(0, 0, \dots, 0)$. Ainsi, la distance d'un point individu par rapport à l'origine (DISTO³) représente son écart par rapport à l'individu moyen.
- ii) La variance (et donc l'écart type) d'une variable réduite est égale à l'unité. Par conséquent, lorsque toutes les variables sont réduites, l'inertie totale du nuage est égale au nombre P de variables.

$$I = \sum_{j=1}^P \sigma_j^2 = \sum_{j=1}^P 1 = P$$

- iii) Une variable centrée et réduite est donc de moyenne nulle et d'écart type égal à l'unité. En outre, si toutes les variables sont centrées et réduites, les variables ont la même importance, (même part $1/P$ d'inertie). Pour des considérations mathématiques, on attribut alors à chaque point individu un poids (masse) égale à la racine carré de $1/N$. Ainsi, la distance d'un point variable par rapport à l'origine est égale à son écart type, donc à l'unité.

$$d^2(x_j^*, 0) = \frac{1}{N} \sum_{i=1}^N (x_{ij}^*)^2 = \frac{1}{N} \sum_{i=1}^N \left(\frac{x_{ij} - \bar{x}_j}{\sigma_j} \right)^2 = \frac{1}{N} \sum_{i=1}^N 1 = 1$$

(où le terme $1/N$ représente le carré de la masse de chaque point individu).

- iv) En regardant à nouveau les formules (3) et (4), nous voyons que si les variables sont centrées et réduites, le coefficient de corrélation linéaire représente exactement le produit scalaire euclidien. Et puisque les variables centrées réduites sont sur la sphère unité (et donc les vecteurs variables centrées réduites sont de norme « 1 »), le produit scalaire est égal au cosinus de l'angle formé par les deux vecteurs variables. Par ailleurs, le fait de centrer les variables correspond à un changement de repère (point de la remarque). La réduction correspond à une homothétie. Ces deux transformations conservent les angles. Par conséquent, l'angle entre deux variables est « parfaitement » traduit (en cosinus) par le coefficient de corrélation linéaire. Et la simple lecture de ces angles sur les graphiques permet d'évaluer les liaisons linéaires (association, oppositions et indépendances linéaires).

h) Exemple d'application

Soit le tableau suivant présentant les caractéristiques des employés d'une entreprise :

individu	Revenu (x 1000)	Dépenses consommation (x 1000)	Taille ménage	Expérience prof. (en années)
1	100	90	5	1
2	150	125	3	7
3	160	95	2	3
4	70	58	6	10

Travail demandé :

- 1) Déterminer le nuage direct

³ Voir II.3. b.

- 2) Calculer l'inertie de ce nuage par rapport au point moyen
- 3) Comparer les distances entre les couples d'individus (1 et 2) et (2 et 3)
- 4) Déterminer les variables centrées réduites
- 5) Calculer la variance de la variable revenu centrée réduite
- 6) Recalculer et comparer les nouvelles distances de la question 3.
- 7) Quels commentaires pouvez-vous faire ?

II.2. Notion de projection, de facteur et de composantes principales

En pratique, dans une analyse, on dispose de plus de 3 variables, sinon l'analyse factorielle ne se justifiera pas. Ces méthodes permettent d'étudier un tableau de données à l'aide de représentations graphiques des nuages de points. Mais lorsqu'on a $P > 3$ variables, il faut faire des représentations en dimension $P > 3$. Ce qui dépasse notre capacité visuelle qui n'est efficace qu'en dimension 1 ou 2.


a) Notion de projection

Le principe de base des méthodes d'analyse factorielle (ACP, AFC, ACM) est donc de construire des plans qui permettent de visualiser le nuage et de déceler les phénomènes intrinsèques qui s'y cachent. Le nuage vu sur le plan est (donc) en fait une projection du nuage réel.


Cependant, toute projection entraîne nécessairement une perte d'information. Il convient dès lors de construire des plans qui minimisent cette perte. Et c'est à ce niveau que se situe l'intérêt de ces méthodes.

Illustrons le besoin de construire des axes et des plans qui donnent une idée (projection) proche de la réalité par deux exemples.

1^{er} exemple de projection : projection d'un crayon sur un plan



La projection sur le plan P_2 donne plus d'informations, par rapport à la projection sur P_1 qui ne permet même pas de deviner l'objet réel.

2^{ème} exemple de projection : projection de 3 points dans un plan

Les projections a' et c' des points a et c gardent la distance réelle entre ces points. Par contre, on a une proximité entre a' et b' qui est en fait fausse.

Une bonne projection doit donner des distances projetées aussi proches de la réalité que possible, et présenter le maximum de points du (d'informations sur le) nuage. En d'autres termes, l'espace (plan) de projection choisi doit donner une configuration des points en projections aussi proche de la configuration réelle que possible. Il faut donc trouver un critère qui nous permet de dire si oui ou non un espace donne des projections satisfaisantes.

Une projection est d'autant meilleure qu'elle donne le maximum de points distincts tout en conservant au mieux les distances réelles.

Etant donné que la configuration fait référence à la disposition, donc aux distances et proximités, c'est à dire encore à la dispersion, on retient comme critère d'appréciation (de l'ajustement) *l'inertie* qui est la somme des variances (dispersions). Ainsi, le meilleur plan est celui qui donne une représentation du nuage avec le plus grand étalement possible.

b) Inertie par rapport à une droite, un plan orthogonal**Définitions**

On définit l'inertie par rapport à une droite comme l'inertie du nuage de points projetés sur la droite. L'inertie par rapport à un plan orthogonal est la somme des inerties par rapport à deux droites orthogonales qui engendrent ce plan.

c) Notions de facteur et de composantes principales

Le principe des méthodes d'analyse factorielle se résume finalement à la recherche des droites passant par le point moyen (origine) et qui donnent une meilleure projection, soit un meilleur étalement du nuage.

Algébriquement, on démontre que ces droites ont pour vecteurs directeurs, les vecteurs propres associées aux valeurs propres de la matrice de corrélation $C = X^*X$, où, rappelons-le, X est la matrice correspondant au tableau de données (actives). L'inertie totale est égale à la somme des valeurs propres.

Définitions

Les droites déterminées sont appelées facteurs ou axes factoriels. Les projections des points sur ces facteurs sont appelées composantes principales. Ce sont donc les coordonnées des points sur les facteurs.

Les valeurs propres sont toutes positives. L'inertie du nuage, par rapport à la droite D_α dirigée par le vecteur propre μ_α est exactement la valeur propre λ_α associée. On dit que λ_α est l'inertie le long de l'axe.

Les valeurs propres sont ordonnées suivant l'ordre décroissant. Le rang et l'importance d'un axe factoriel sont relatifs au rang de la valeur propre associée. Ainsi, le facteur le plus important est associé à la 1^{ère}, ou la plus grande valeur propre.

Un axe factoriel est en fait une combinaison linéaire des variables (actives). De sorte que le principe des méthodes d'analyse factorielle peut encore se traduire comme la recherche des combinaisons linéaires des variables qui maximisent l'inertie en projection. Leur nombre est égal à P , le nombre de variables actives initiales.

Les axes factoriels sont deux à deux perpendiculaires. Deux axes factoriels engendrent un *plan factoriel*. Le plan factoriel engendré par les deux premiers facteurs est appelé plan factoriel principal. C'est le plan qui donne la plus grande dispersion (ou inertie).

d) Choix du nombre d'axes à retenir pour l'analyse

Chaque axe factoriel restitue une part de l'information (inertie) contenue dans le nuage de points. Cette part est proportionnelle à la valeur propre λ associée, et est égale à λ/P (en %).

Il n'y aurait pas de gain à analyser tous les P axes factoriels. Il faut donc un critère qui nous permette de résumer l'information dans le nuage à partir d'un nombre réduit d'axes.

- Le critère le plus simple stipule qu'il faut retenir pour l'analyse les premiers axes qui nous donnent un cumul d'inertie compris entre 60% et 80%. (*Comprendre en cela que nous devons interpréter au moins 60% de l'inertie, même si on n'excède pas 80%*).

Il existe d'autres critères de choix du nombre d'axes :

- Le critère de Kaiser qui suggère de retenir les axes dont les valeurs propres associées sont supérieures à la moyenne (qui est 1 dans le cas de l'ACP, mais à calculer pour les méthodes qualitatives). Rappelons que les variables (actives) étant centrées réduites, chacune d'elles apportent une part $1/P$ d'information (inertie). Un facteur dont la valeur propre est supérieure à 1 apporte donc une part d'information supérieure à la moyenne.
- Le critère du coude (ou de Cattle) se réfère à la forme dégressive des valeurs propres et cherche à identifier les axes les plus riches en information. Les valeurs propres formant une suite décroissante, cette règle cherche à détecter l'existence d'un coude ou d'un pallier correspondant à une forte diminution relative de l'inertie. De façon visuelle, le coude se situe sur un axe sur lequel l'écart absolu de la valeur propre associée par rapport à la valeur propre directement inférieure est supérieur au même écart absolu par rapport à la valeur propre directement supérieure.

On considère qu'au-delà du coude il n'y a plus « grand-chose » et on retient alors les axes du plus important jusqu'à celui où se situe le coude.

Remarque : Aucun critère n'est parfait. En général, les premiers axes ne donnent que les tendances globales, et même souvent des évidences. Les axes de rangs élevés révèlent parfois des phénomènes très intéressants. En outre, il est parfois préférable de combiner les critères pour identifier les axes pertinents.

II.3 Aides à l'interprétation

a) Pourquoi des aides à l'interprétation

Les débutants ont toujours un mouvement de recul devant les aides à l'interprétation qu'il trouve quelque peu rébarbatif, et beaucoup moins suggestive que les graphiques. Ces aides sont pourtant indispensables, car la simple observation des graphiques peut conduire à des résultats erronés, particulièrement quand les individus sont de poids distincts.

Quatre types d'aides sont généralement utilisés pour l'interprétation des analyses factorielles : la DISTO, le COS2 (lire cosinus carré) et les contributions (CTR) et la V. Test (valeur test).

b) La DISTO

La DISTO se calcule pour les points individus (et les modalités dans le cas des analyses qualitatives) et mesure la distance par rapport au point moyen (qui est l'origine). La DISTO est un critère de l'originalité d'un point individu. Un point est d'autant plus original ou atypique qu'il est éloigné de l'origine, et donc que sa DISTO est grand. On veillera donc dans une analyse à identifier et à interpréter les points les plus originaux. *En fait un point est original lorsqu'il sort de l'ordinaire (qui est représenté par la moyenne). Atypique peut s'interpréter comme « hors norme ».*

c) Le COS2

Pour les points individus

Les COS2 des points individus expriment la qualité de représentation des points en projections sur un axe factoriel, en comparaison à leur configuration réelle. Cela signifie que la distance entre deux points individus en projection n'est en fait proche de la réalité, et donc interprétable, que s'ils sont bien représentés, c'est-à-dire ont des COS2 proches de 1. **Les points les mieux représentés, et interprétables sont donc ceux qui ont des COS2 proches de 1 (cela est aussi vrai pour les points variables).** *De façon simple, le COS2 permet de juger si ce qu'on observe sur les graphiques est conforme à la réalité.* Toutefois, deux points proches dans tous les plans factoriels se ressemblent en tous points de vue, indépendamment de leurs COS2.

Mathématiquement, le COS2 d'un point sur un axe factoriel mesure le carré cosinus de l'angle que fait le point avec l'axe (cela est aussi vrai pour les points variables) dans l'espace R^p .

Par exemple, si le COS2 d'un point sur un axe est égal à 1, alors ce point est sur l'axe, et c'est révélateur d'une très bonne représentation sur cet axe. Par contre, si le COS2 est égal à 0, alors ce point est situé sur une direction orthogonale à l'axe, et ce point est très mal représenté par l'axe et la projection sur l'axe se confondra avec l'origine.

Le COS2 mesure aussi la part d'originalité d'un point individu expliqué par l'axe. Les individus bien représentés sur un axe sont bien illustrés par cet axe, en ce sens que leur originalité, relativement à l'individu moyen est bien traduite par cet axe, ou encore que l'information initiale relative à ces individus est bien restituée par cet axe. Par exemple, un COS2 = 0,85 sur un axe signifie que celui-ci explique 85% du comportement de cet axe.

Lorsque le COS est médiocre sur les axes, on calcule la *qualité de représentation* (QLT) dans le plan. La QLT est la somme des COS2 sur les deux axes du plan.

La somme des COS2 d'un point individu sur tous les axes est égale à 1.

Pour les points variables

Le COS2 d'une variable sur un axe indique le degré de liaison entre la variable et l'axe considéré.

Le fait que les variables soient centrées réduites apporte une simplification à l'interprétation du nuage des variables.

D'une part, le COS2 d'une variable coïncide avec le carré de la coordonnée factorielle (coordonnée du point sur le facteur ou axe). De ce fait, une variable est d'autant bien représentée sur un axe que sa coordonnée sur cet axe est proche de 1 ou de -1. Or chaque variable étant réduite appartient à la sphère unité (en dimension n). Par conséquent, une variable est bien représentée si elle est proche du cercle de corrélation (projection de la sphère dans le plan). Cette dernière remarque permet de repérer géométriquement les variables bien représentées, à partir de leur position sur le graphique par rapport au cercle de corrélation.

D'autre part, la coordonnée d'une variable sur un axe représente la corrélation de cette variable avec cet axe. Les variables bien représentées sur un axe illustrent donc bien cet axe. Géométriquement, ce sont en fait les variables qui forment un faible angle avec l'axe sur le graphique.

La corrélation des variables avec les axes permet en général de déterminer le sens de ces axes. Cependant, cela n'est pas toujours possible. Il peut arriver des cas où aucune variable ne permet

de déterminer le sens d'un facteur. Dans ces cas, on recherche le sens de l'axe à partir des individus représentatifs (ou originaux).

Le COS2 permet donc de déceler les vraies et fausses proximités. Du fait de l'orthogonalité des facteurs, la qualité de représentation d'un point (individu ou variable) sur un plan factoriel est la somme des COS2 du point sur les deux axes factoriels qui engendrent ce plan.

d) La contribution (CTR)

Nous avons déjà signalé qu'un axe factoriel restitue une part de l'information (inertie) contenue dans le nuage, et que cette part est égale à λ/p (p est le nombre de variables). Cette part d'information de l'axe peut être décomposée point par point. La part d'un point représente son influence dans la formation de l'axe et est appelée contribution (CTR). La somme des contributions de tous les points individus sur un axe est égale à 1. Mathématiquement, la contribution d'un point sur un axe représente le rapport du carré de sa coordonnée sur la valeur propre de l'axe.

Les contributions permettent d'identifier les individus très influents (et éventuellement aberrants) d'une analyse, pouvant déterminer à eux seuls le positionnement des axes. Ce sont aussi les individus les plus originaux.

Ces individus, par leur influence peuvent ausculter d'autres phénomènes intéressants dans un vaste tableau de données. Il importe, dans une analyse, de les identifier, de les interpréter au préalable et de recommencer l'analyse en les plaçant dans un état où ils n'influenceront plus le positionnement des axes. Cela s'appelle les mettre en *supplémentaire* ou en *élément illustratif*.

e) La V. test

Elle indique la significativité des modalités et variables. **L'élément sera significatif (et dont interprétable) si ce coefficient est supérieur ou égal à 2 en valeur absolue.**

f) Notion d'élément actif et d'élément supplémentaire

Dans un tableau, les variables peuvent être nombreuses et de divers domaines ou thèmes. Avant de procéder à une analyse, il convient de définir un thème précis et de choisir les variables cohérentes avec ce thème. Ces variables constituent les **variables actives**. Ce sont les seules qui seront soumises aux calculs, participeront à la construction des facteurs et qui seront utilisées pour comparer et décrire les individus.

Il est toutefois possible d'introduire d'autres variables dans l'analyse, sans leur laisser l'occasion d'intervenir dans les calculs. Ces dernières sont appelées **variables illustratives ou supplémentaires** et utilisées pour illustrer ou caractériser les groupes d'individus et les relations entre variables actives. Notons que *même des variables qualitatives peuvent être introduites en supplémentaires dans une ACP* qui, rappelons-le, est adaptée aux variables quantitatives.

En ce qui concerne les individus, seuls ceux qui sont choisis **actifs** influenceront la construction des axes factoriels, et donc auront des CTR non nuls. Des individus peuvent aussi être introduits en **supplémentaires** à titre **illustratif**, afin de voir leur positionnement par rapport aux individus actifs.

Mathématiquement, mettre un point (individu ou variable) en supplémentaire revient à lui attribuer un coefficient de pondération nul. Il reste alors **passif** dans les calculs et a une CTR nulle.

Les individus supplémentaires permettent aussi de vérifier la validité empirique des hypothèses formulées après une ACP. Par exemple, la mise d'individus en « hors échantillon » en éléments supplémentaires permet de savoir si les comportements observés dans l'échantillon actif se retrouvent dans l'ensemble de la population.

La mise en supplémentaire d'un élément peut être justifiée pour des observations relevées dans des conditions douteuses, très différentes des autres, ou simplement aberrantes ou ayant perturbé ou trop influencé une analyse préliminaire.

g) Remarque :

Seuls les points (individus et variables) actifs figurent dans la matrice X. Les éléments illustratifs peuvent toutefois être représentés dans les plans factoriels, en exprimant leurs coordonnées dans le système d'axes factoriels.

Chap. III. ANALYSE EN COMPOSANTES PRINCIPALES (ACP)

Ce chapitre présente la méthode dite *Analyse en composantes Principales (ACP)* qui est l'analyse factorielle des données sur variables quantitatives.

III.1. Objet et principe de l'ACP

a) Objet de l'ACP

L'ACP est une technique statistique qui permet de résumer l'information contenue dans un vaste tableau de données quantitatives à partir de représentations graphiques. Elle fournit une carte des unités d'observations (individus, ménages, entreprises, pays, ...) en fonction de leur proximité, et une carte des variables en fonction de leur corrélation linéaire. Cette méthode permet notamment de :

- Repérer les faits significatifs (associations, oppositions et indépendances linéaires entre les variables) qui structurent les individus en groupes et qui départagent ces groupes. En d'autres termes, dans le nuage d'individus, qui ressemble à qui, et de quel point de vue ?
- Mettre en évidence les individus dont les comportements sont atypiques et qu'est ce qui les caractérise (à partir des DISTO et contribution) ;
- Rechercher si l'information contenue dans le tableau brut ne pourrait pas être obtenue avec un plus petit nombre de variables, celles-ci pouvant être des variables construites (en utilisant les critères de choix des axes).

b) Principe de l'ACP

L'ACP permet de mettre en évidence les caractéristiques principales d'une masse de données quantitatives, sous forme de visualisation graphique. Ces graphiques sont construits selon le principe de maximisation de l'inertie du nuage de points projetés. La méthode fournit des plans de visualisation à la fois pour le nuage direct (des individus) et pour le nuage dual (des variables). Ces plans construits à partir des axes factoriels importants retenus selon les critères énumérés. L'interprétation du graphique des individus se fait à partir de celui des variables se fait alors en transitant par les axes factoriels, et en se servant des aides que produit le logiciel.

Comme signalé, on peut introduire des variables et des individus en éléments supplémentaires. Seules les variables quantitatives peuvent être introduites comme actives. Les variables qualitatives ne peuvent être qu'illustratives. Mais il est aussi possible d'introduire des variables quantitatives en supplémentaire. Les variables supplémentaires ne participent alors pas à la formation des axes, mais servent à illustrer.

III.2. Etapes pour la réalisation informatique d'une ACP (à partir du progiciel Spad)

Avant tout il faut disposer d'une base de Spad. Elles ont l'extension «.sba ». Si les données sont enregistrées dans Spad ou SPSS, passez directement à l'étape 3.

Etape 1 : Exportation des données à partir d'Excel :

- i) Activer la feuille sur laquelle se trouvent les données, et vérifier qu'il n'y a que les données utiles sur la feuille ;
- ii) Enregistrer en type « texte (séparateur : tabulation) ». Seule la feuille active s'enregistre. Le logiciel vous en informera, choisir successivement « OK », puis « OUI » ;
- iii) Fermer le fichier sans plus l'enregistrer.

(Signalons qu'il s'agit là d'un mode parmi tant d'autres comme dBase, et autres types de séparateurs : espace, point-virgule, ..., ou même Excel.)

Etape 2 : Importation des données dans Spad : Ouvrir Spad et réaliser l'importation du fichier texte : à partir du menu de Spad4 : base – importer – importation de texte (pour Spad 5.5, prendre importation fichier ascii – nouveau et donner un nom à votre projet). Toujours vérifier que le séparateur des décimales est bien indiqué. Faire « suivant » et déclare les types des variables et créer la base sous Spad en exécutant.

Etape 3. Mises en forme dans Spad : Ouvrez la base dans Spad à partir de l'éditeur des données et faire des aménagements si nécessaire, notamment les mises en forme. Il est possible d'ouvrir un fichier de données SPSS à partir de cet éditeur. Vous avez des fenêtres différentes pour : les valeurs, variables, modalités, ...

Etape 4. Construction de la méthode : Ouvrir une filière vide dans Spad et sélectionner la base (double clic dans l'icône : BASE). Insérer l'icône de la méthode et déposer y la méthode « Composantes principales » à partir de la fenêtre des méthodes. Paramétrer la filière en indiquant les variables actives /illustratives, de même que les individus actifs/ illustratifs. Signaler, s'il y a lieu, la variable de poids, et indiquer (dans paramètres) si vous voulez les résultats pour les individus et si oui pour combien de facteurs. Enregistrer la filière et exécuter la méthode.

Trois (ou quatre pour Spad5) icônes de résultats sont créés et accessibles par double clics. La première (jaune) donne les éléments d'aide à l'interprétation. La seconde (bleu verdâtre) permet de réaliser les graphiques (graphique – nouveau). Les individus se représentent avec les modalités des variables qualitatives (qui sont illustratives). Les variables continues (actives et supplémentaires) se représentent ensemble sur un même graphique.

III.3. Règles et démarche pour l'interprétation des résultats d'une ACP Démarche

pour l'interprétation :

i) Commencer par commenter l'individu moyen. Toutes les coordonnées sont relatives à la moyenne ; ii) Déterminer le nombre d'axes à retenir pour l'analyse (à partir des trois critères) ; iii) Repérer ensuite les variables qui illustrent bien les axes retenus parmi celles bien représentées. Ce sont celles qui ont de fortes coordonnées sur l'axe, ou encore qui, graphiquement, sont proches du cercle et forment un petit angle avec l'axe. iv) Déterminer les associations et les oppositions des variables, ainsi que les indépendances linéaires, soit à partir de la matrice des corrélations⁴, soit graphiquement. Deux variables sont associées si elles ont entre elles une forte corrélation linéaire positive, ce qui géométriquement s'exprime par un angle réduit entre les points variables. Si la corrélation linéaire est forte mais négative, les variables sont opposées. Graphiquement, elles formeront un angle proche de l'angle plat (180°). Enfin, si la corrélation linéaire entre deux variables est proche de zéro, celles-ci sont linéairement indépendantes, et cela se vérifie sur le graphique par un angle proche de 90° entre ces variables. Donner alors le sens des axes à partir des variables.

Remarque : A ce niveau on peut maintenant interpréter le nuage des individus par les variables en transitant par les axes. Lorsqu'un individu a une forte (resp. faible) valeur pour une variable, il a de même de fortes (resp. faibles) valeurs pour toutes les autres variables associées à cette dernière, et de faibles (resp. fortes) valeurs pour les variables opposées.

Un point se trouve du « côté » des variables pour lesquelles il a de fortes valeurs, et à l'opposé des variables pour lesquelles il a de faibles valeurs.

v) On commence par interpréter les individus originaux ou atypiques : les individus qui ont de fortes CTR sur les axes à interpréter ou de fortes DISTO (distance par rapport à l'origine).

Identifiez et commentez les, et, au besoin, les mettre en supplémentaires pour éliminer leur influence sur le positionnement des autres points. vi). Déterminer pour chaque axe à interpréter les points bien représentés. Ce sont ceux qui ont des forts COS2. Déterminer aussi les points qui, sans remplir la

⁴ La matrice de corrélation est une des aides à l'interprétation donnée par le logiciel est un tableau qui présente les corrélations linéaires entre toutes la variables actives de l'analyse.

condition précédente ont une bonne qualité de représentation (QLT) sur les plans à interpréter. La QLT d'un plan est la somme des COS2 des deux axes. vii) Commenter alors ces points. viii) Repérer si possible les regroupements (une partition) d'individus par affinités. Cela se fait aussi parfois à partir des modalités d'une variable qualitative illustrative. On n'utilisera ici que les modalités bien représentées, c'est-à-dire qui ont des coordonnées élevées (valeur test supérieure ou égale à 2 en valeur absolue).

III.4. Exemple d'application

Nous utilisons une ACP pour analyser les caractéristiques des employés d'une entreprise. Cet exemple a un caractère purement pédagogique. Les données sont présentées dans le tableau suivant.

Tableau : Caractéristiques des employés de l'entreprise DADY.SA

Individu	Revenu (x 1000)	Dépenses de consommation (x 1000)	Taille ménage	Expérience prof. (en années)	Niveau d'instruction
1	100	90	5	1	Secondaire
2	150	125	3	7	Supérieur
3	160	95	2	3	Supérieur
4	70	58	6	10	Secondaire
5	140	90	2	1	Supérieur
6	150	80	3	12	Supérieur
7	45	30	7	8	Secondaire
8	60	46	7	6	Primaire
9	75	65	6	2	Secondaire
10	50	50	6	2	Primaire
11	35	40	5	6	Primaire
12	60	60	4	5	Secondaire

Nous introduisons toutes les variables quantitatives en actifs, et le niveau d'instruction comme variable illustrative. On a les résultats suivants :

STATISTIQUES SOMMAIRES DES VARIABLES CONTINUES

EFFECTIF TOTAL : 12 POIDS TOTAL : 12.00

NUM . IDEN - LIBELLE	EFFECTIF	POIDS	MOYENNE	ECART-TYPE	MINIMUM	MAXIMUM
1 . C2 - Revenu (x 1000)	12	12.00	91.25	44.49	35.00	160.00
2 . C3 - Dépenses (x 1000)	12	12.00	69.08	26.28	30.00	125.00
3 . C4 - Taille ménage	12	12.00	4.67	1.75	2.00	7.00
4 . C5 - Expérience Prof (en	12	12.00	5.25	3.44	1.00	12.00

i) Commentaire du point moyen : Le logiciel donne les statistiques élémentaires sur les variables. En moyenne, un individu gagne 91 250F et dépense pour sa consommation 69 083F. La taille moyenne des ménages est de 4.67 et chaque employé de l'entreprise a déjà travaillé en moyenne pendant 5,25 ans.

ii) Le choix du nombre d'axes : se fait à partir de l'histogramme des valeurs propres. Le premier axe à lui seul nous donne déjà plus de 60% de l'inertie. L'application du critère de Kaiser conduit à choisir les deux premiers axes. Nous avons donc à commenter un plan factoriel. Nous sommes partis de 4 variables, et nous avons à commenter juste deux axes qui donnent 92.17% de l'inertie.

VALEURS PROPRES
 APERCU DE LA PRECISION DES CALCULS : TRACE AVANT DIAGONALISATION .. 4.0000
 SOMME DES VALEURS PROPRES 4.0000

HISTOGRAMME DES 4 PREMIERES VALEURS PROPRES


NUMERO	VALEUR PROPRE	POURCENT.	POURCENT. CUMULE
1	2.6847	67.12	67.12
2	1.0021	25.05	92.17
3	0.2347	5.87	98.04

iii) Explication des axes par les variables qui les illustrent et leurs associations⁵. On peut observer pour cela les variables qui ont de fortes coordonnées sur les axes, ou alors celles bien représentées qui forment un angle petit avec les axes 1 et 2. Les graphiques des variables permettent de voir que toutes les variables sont bien représentées. Le revenu et la consommation sont corrélés et anticorrélés à la taille du ménage. Toutes ces trois variables sont linéairement indépendantes de l'expérience professionnelle. L'expérience professionnelle illustre l'axe 2, alors que les autres variables illustrent l'axe 1. Ainsi, l'axe 1 oppose les individus qui ont de forts revenus (supérieurs à 91 250F) et des fortes dépenses, soit les riches, à ceux qui vivent dans des ménages de grande taille (au moins 5 personnes) et sont pauvres. L'axe 2 oppose les individus de forte expérience professionnelle (plus de 5 ans) à ceux qui ont des faibles expériences professionnelles.


Graphique des variables

Le tableau qui suit permet de voir que l'individu 6 a une très forte contribution (38,9) sur l'axe 2. Cet individu est caractérisé par une très grande expérience professionnelle ainsi que le démontre sa forte coordonnée positive sur l'axe 2 (sens de la flèche de la variable considérée). Il a aussi un fort revenu (selon le tableau des données) pourtant il n'est pas bien illustré par l'axe 1, puisqu'il a un faible COS2 (0,28) sur cet axe. En remontant au tableau, on constate que ses valeurs pour les deux autres variables qui illustrent l'axe 1 sont proches des valeurs moyennes. Il est préférable de reprendre l'analyse en éliminant l'influence de l'individu 6 afin de voir les positionnements réels des autres points.

a) Avec l'individu 6 actif



b) Avec l'individu 6 en supplémentaire



⁵ Nous fusionnons ici les points iii) et iv) de la démarche d'interprétation.

iv) Les points à fortes CTR

COORDONNEES, CONTRIBUTIONS ET COSINUS CARRES DES INDIVIDUS																	
AXES 1 A 4																	
INDIVIDU			COORDONNEES					CONTRIBUTIONS					COSINUS CARRES				
IDENTIFI	P.REL	DISTO	1	2	3	4	0	1	2	3	4	0	1	2	3	4	0
1	8.33	2.23	-0.58	-1.22	0.63	-0.06	0.00	1.1	12.4	14.3	0.4	0.0	0.15	0.67	0.18	0.00	0.00
2	8.33	7.44	-2.49	0.67	0.77	-0.46	0.00	19.2	3.8	21.1	22.5	0.0	0.83	0.06	0.08	0.03	0.00
3	8.33	6.11	-2.39	-0.38	-0.37	0.33	0.00	17.8	1.2	4.7	11.6	0.0	0.94	0.02	0.02	0.02	0.00
4	8.33	2.89	1.08	1.27	0.30	-0.12	0.00	3.6	13.4	3.1	1.4	0.0	0.41	0.56	0.03	0.00	0.00
5	8.33	5.69	-2.08	-1.01	-0.56	0.16	0.00	13.4	8.6	11.3	2.8	0.0	0.76	0.18	0.06	0.00	0.00
6	8.33	6.67	-1.36	2.16	-0.24	0.27	0.00	5.8	38.9	2.0	7.9	0.0	0.28	0.70	0.01	0.01	0.00
7	8.33	5.71	2.29	0.62	-0.01	0.26	0.00	16.3	3.2	0.0	7.3	0.0	0.92	0.07	0.00	0.01	0.00
8	8.33	3.09	1.69	0.09	0.40	0.27	0.00	8.9	0.1	5.7	7.9	0.0	0.92	0.00	0.05	0.02	0.00
9	8.33	1.63	0.64	-1.01	0.42	0.14	0.00	1.3	8.5	6.2	2.1	0.0	0.25	0.63	0.11	0.01	0.00
10	8.33	2.86	1.30	-1.08	-0.01	0.01	0.00	5.2	9.7	0.0	0.0	0.0	0.59	0.41	0.00	0.00	0.00
11	8.33	2.91	1.51	0.04	-0.71	-0.36	0.00	7.0	0.0	18.1	13.9	0.0	0.78	0.00	0.17	0.04	0.00
12	8.33	0.76	0.39	-0.16	-0.61	-0.46	0.00	0.5	0.2	13.4	22.2	0.0	0.20	0.03	0.50	0.27	0.00

En reprenant l'analyse, il apparaît que, les variables monétaires qui étaient bien distinctes lorsque l'individu 6 était actif se confondent lorsqu'il ne l'est plus. Cet individu contribue donc à la baisse de la corrélation linéaire entre ces variables. Ce qui stipule que la consommation de cet individu n'est pas corrélée à son revenu. Les données brutes le confirment : il gagne 150 000F et ne consomme que 80 000F.

v) Identification des individus bien représentés

Si l'on considère un $COS2 > 0,60$ comme bon, alors sur l'axe 1, les individus bien représentés sont : 2, 3, 5, 7, 8 et 11 ; Sur l'axe 2, nous avons le 9 et le 10. Les individus 1 et 4, sans être bien illustrés par un axe sont tout de même bien représentés dans le plan. On remarque par ailleurs que l'individu 6 a des CTR nulles, ce qui justifie qu'il est en supplémentaire. En outre, seule la modalité « supérieur » de la variable qualitative est bien représentée, et ce sur l'axe 1, vu sa forte coordonnée sur cet axe et surtout sa valeur test supérieure à 2 en valeur absolue.

COORDONNEES, CONTRIBUTIONS ET COSINUS CARRES DES INDIVIDUS
INDIVIDUS ACTIFS (AXES 1 A 4)

INDIVIDUS			COORDONNEES					CONTRIBUTIONS					COSINUS CARRES				
IDENTIFICATEUR	P.REL	DISTO	1	2	3	4	0	1	2	3	4	0	1	2	3	4	0
1	9.09	2.34	-0.94	-0.97	-0.69	-0.20	0.00	2.8	10.3	18.1	5.1	0.0	0.38	0.40	0.20	0.02	0.00
2	9.09	8.37	-2.32	1.61	-0.52	-0.32	0.00	17.2	28.5	10.1	13.4	0.0	0.65	0.31	0.03	0.01	0.00
3	9.09	6.91	-2.56	0.17	0.37	0.44	0.00	20.9	0.3	5.1	24.3	0.0	0.95	0.00	0.02	0.03	0.00
4	9.09	4.15	1.32	1.55	-0.12	0.04	0.00	5.6	26.2	0.5	0.2	0.0	0.42	0.58	0.00	0.00	0.00
5	9.09	6.43	-2.40	-0.62	0.51	0.20	0.00	18.3	4.2	9.7	4.9	0.0	0.89	0.06	0.04	0.01	0.00
7	9.09	5.78	2.33	0.50	0.03	0.34	0.00	17.2	2.8	0.0	14.4	0.0	0.94	0.04	0.00	0.02	0.00
8	9.09	2.81	1.60	0.04	-0.42	0.26	0.00	8.2	0.0	6.6	8.4	0.0	0.91	0.00	0.06	0.02	0.00
9	9.09	1.36	0.31	-1.00	-0.51	0.01	0.00	0.3	11.0	10.0	0.0	0.0	0.07	0.74	0.19	0.00	0.00
10	9.09	2.43	0.94	-1.24	-0.09	-0.10	0.00	2.8	16.7	0.3	1.4	0.0	0.36	0.63	0.00	0.00	0.00
11	9.09	2.72	1.44	-0.02	0.76	-0.28	0.00	6.6	0.0	22.0	9.7	0.0	0.76	0.00	0.21	0.03	0.00
12	9.09	0.69	0.29	-0.02	0.68	-0.38	0.00	0.3	0.0	17.6	18.1	0.0	0.12	0.00	0.67	0.20	0.00

INDIVIDUS ILLUSTRATIFS (AXES 1 A 4)

INDIVIDUS			COORDONNEES					CONTRIBUTIONS					COSINUS CARRES				
IDENTIFICATEUR	P.REL	DISTO	1	2	3	4	0	1	2	3	4	0	1	2	3	4	0
6	9.09	9.98	-0.91	2.91	0.51	0.66	0.00	0.0	0.0	0.0	0.0	0.0	0.08	0.85	0.03	0.04	0.00

COORDONNEES ET VALEURS-TEST DES MODALITES
AXES 1 A 4


MODALITES			VALEURS-TEST					COORDONNEES					DISTO.				
IDEN - LIBELLE	EFF.	P.ABS	1	2	3	4	0	1	2	3	4	0	1	2	3	4	0
5 . Niveau d'inst																	
AA_1 - C6=primaire	3	3.00	1.5	-0.9	0.3	-0.3	0.0	1.33	-0.41	0.08	-0.04	0.00	1.93				
AA_2 - C6=secondaire	5	5.00	1.1	0.0	-0.7	-0.4	0.0	0.66	0.01	-0.12	-0.04	0.00	0.45				
AA_3 - C6=superieur	3	3.00	-2.8	0.8	0.5	0.7	0.0	-2.43	0.39	0.12	0.10	0.00	6.07				

vi) Interprétation des individus

Les individus 2, 3 et 5 ont des revenus et dépenses de consommations élevés, et vivent dans des ménages de faible taille. Ils ont un niveau d'instruction supérieur. A l'opposé, les individus 7, 8 et 11 sont « pauvres » et vives dans des ménages de plus de 4,67 personnes. L'individu 4 a une forte expérience professionnelle, mais aussi vit dans un ménage élevé et est « pauvre ». Enfin, les

individus 1, 9 et 10 ont de faibles expériences professionnelles. De façon globale, il se dégage deux grands groupes : les riches (2, 3 et 5) et les pauvres (10, 11, 8, 7 et 4).

Graphique des individus



Remarques finales et limites de l'ACP :

- 1) Lorsque la population est très nombreuse, il est impossible de citer tous les individus, ni même d'identifier tous ceux qui sont bien représentés sur les axes. On se contente de former des groupes à partir des graphiques, et on commente ces groupes en citant quelques individus bien représentés.
- 2) **Limites de l'ACP** : L'ACP est une méthode purement descriptive. On ne saurait donc en tirer des conclusions de type : les riches n'aiment pas vivre nombreux.
- 3) Par ailleurs, l'ACP n'est efficace que lorsque les liaisons entre variables peuvent être mesurées par le coefficient de corrélation linéaire. Ce n'est que dans ce cas qu'elle permet de réduire la dimension de l'espace d'analyse. Sinon, chaque variable active définira son propre axe. Les phénomènes de non linéarité conduisent donc à des mauvaises interprétations s'ils ne sont pas détectés. Dans de tels cas, il faut transformer les variables ou recourir à des méthodes factorielles non linéaires telles que l'AFC et l'ACM.

Chap. IV. ANALYSE FACTORIELLE DES CORRESPONDANCES SIMPLES (AFC)

L'objet de ce chapitre est d'introduire l'analyse factorielle non linéaire, notamment l'étude de la liaison entre deux variables qualitatives et des correspondances entre modalités.

IV.1. Objet et Description de la méthode

a) Objet de l'AFC

L'analyse factorielle des correspondances simples étudie la liaison, dite encore correspondances, entre deux variables qualitatives et détermine les modalités des variables qui participent à la liaison (les attractions, répulsions et indépendances). Il s'agit donc en fait de déterminer l'existence d'une liaison significative entre deux caractères qualitatifs, et de déceler les modalités des caractères qui contribuent à la liaison. L'AFC se prête aux données se présentant sous la forme d'un tableau de contingence.

L'AFC va au-delà d'une analyse du tableau des contributions à la liaison à la suite d'un test du khi deux. En effet, la première analyse permet de déceler des couples de modalités des deux caractères qui s'associent ou se repoussent. Mais l'AFC, en plus de ce test qu'il réalise, révèle les correspondances (ou associations) et les répulsions entre modalités de deux variables (*même si le test de khi deux n'a pas rejeté l'hypothèse d'indépendance*).

b) Description de la méthode AFC

Commençons d'abord par définir les concepts de profils.

Un tableau de contingence est un tableau qui ventile une population entre les modalités de deux caractères qualitatifs, l'un en ligne et l'autre en colonne). A l'intersection d'une modalité ligne et d'une modalité colonne se trouve le nombre d'individus présentant à la fois les deux modalités.

Considérons le tableau de contingence suivant : N_{ij} est le nombre d'individus de la population statistique qui présentent à la fois la modalité « X_i » du caractère X et la modalité Y_j du caractère Y. Les termes $N_{i.}$ (resp. $N_{.j}$) sont les effectifs marginaux lignes (resp. Colonnes).

		Modalités de la variable colonne (Y)					
		Y_1	...	Y_j	...	Y_Q	Total
Modalités de la variable ligne (X)	X_1	N_{11}		N_{1j}		N_{1Q}	$N_{1.}$
	X_i			N_{ij}			$N_{i.}$
	X_p						
	Total	$N_{.1}$		$N_{.j}$		$N_{.Q}$	N

Le tableau des **profils lignes** s'obtient en divisant chaque effectif conjoint « N_{ij} » du tableau par l'effectif marginal « $N_{i.}$ » de la ligne correspondante.

Le tableau des **profils colonnes** s'obtient en divisant chaque effectif conjoint « N_{ij} » du tableau par l'effectif marginal « $N_{.j}$ » de la colonne correspondante.

Ces définitions rappelées, nous pouvons alors décrire le principe de l'AFC. En AFC, le tableau brut n'est pas directement analysé. Il est transformé en deux tableaux de profils : un tableau des profils lignes et un tableau des profils et colonnes. On effectue ensuite une AC²P sur chacun de ces tableaux. Ainsi l'AFC consiste en une double ACP sur les tableaux des profils. Dans chacune des ACP, le poids d'une modalité (ligne ou colonne) est égal à sa fréquence marginale. Pour le tableau des profils lignes, les modalités lignes sont considérées comme les individus les modalités colonnes comme les variables, et inversement pour le tableau des profils colonnes.

La distance utilisée ici est la distance du khi deux, et l'inertie est proportionnelle au khi deux : $I = \chi^2/N$.

Tout le raisonnement s'effectue donc en termes de profils. La décomposition de cette inertie (qui mesure donc la liaison) suivant les axes factoriels donne l'importance des différents axes. Ainsi, l'inertie d'un axe factoriel (évaluée par la valeur propre) mesure la part de la liaison qu'il représente. Deux variables sont indépendantes si les profils de leurs modalités sont identiques au profil moyen. Deux modalités d'une même variable qui ont le même profil sont semblables et seront confondues en projection sur les plans factoriels.

Les graphiques des nuages de points individus issus des deux ACP sur les profils sont ensuite superposés en respectant les rangs des axes factoriels. C'est à dire que les plans factoriels d'axes de même rang, issus des deux ACP sur chaque tableau de profils (lignes et colonnes), sont superposés. C'est l'interprétation de ces superpositions qui permet de déceler les correspondances et oppositions.

Le nombre d'axes factoriels est $\text{Min}(P, Q) - 1$.

IV.2. Réalisation, Règles et démarche d'interprétation d'une AFC

La démarche informatique pour réaliser une AFC reste semblable à celle de l'ACP, à la différence que c'est la méthode « croisement des variables et correspondances simples » qui sera choisie. Aussi, le paramétrage présente quelques différences. Au départ on dispose d'un tableau de données individuelles, et on construit le tableau de contingence en indiquant les variables (ligne et colonne).

Les éléments d'aides à l'interprétation sont les CTR et les COS2. Le fait qu'en AFC chaque point (modalité) soit affecté d'un poids représentant sa fréquence marginale particularise un peu l'interprétation. La contribution d'un point (en fait une modalité) «i» à l'inertie d'un axe « α » est $\text{CTR}_{\alpha}(i) = f_i \cdot F_{\alpha}(i) / \lambda_{\alpha}$, où f_i est la fréquence marginale de l'individu «i», $F_{\alpha}(i)$ sa coordonnée sur l'axe « α » et λ_{α} la valeur propre de l'axe considéré.

Ainsi, la CTR d'un point dépend de son poids. Un point peut avoir une forte coordonnée sur un axe sans pour autant contribuer fortement à l'inertie de celui-ci. **On dira qu'un point a une forte contribution si sa CTR est particulièrement grande et excède son poids.**

L'analyse pour l'interprétation pourra suivre les étapes suivantes :

- i) Interpréter la répartition de la population par modalité de chaque variable, qui est donnée par la statistique « P. Rél » (le poids réel).
- ii) Interpréter le test du Khi deux ;
- iii) Déterminer le nombre d'axes à retenir ;
- iv) Identifier les points ayant de fortes CTR sur les axes. Ce sont eux qui fixent la position de l'axe, et qui lui donnent une signification ou qui l'expliquent). Commenter alors les associations et oppositions entre ces points. Ceux du même côté de l'axe (même signe de la coordonnée) sont associés ou se correspondent. Et ceux ayant des signes contraires s'opposent ou se repoussent. Cela donne aussi le sens des axes.
- v) Déterminer les points bien représentés (bons COS2). Deux points (modalités) ayant des COS2 élevés et proches dans un plan factoriel sont effectivement proches (semblables ou associés) dans la réalité. S'il s'agit de modalités du même caractère, cela signifie qu'elles ont des profils voisins, et sont donc semblables. Mais si elles appartiennent à différents caractères, cela signifie qu'elles sont associées, et contribuent à la liaison. Aussi, deux modalités des caractères qui sont opposées manifestent ainsi leur répulsion réciproque. Toutefois, l'interprétation des positionnements mutuels se fait en tenant compte de certaines propriétés des relations dites barycentriques qui confèrent une certaine particularité à l'interprétation des AFC (et ACM).

Relations barycentriques

1) En projection sur un axe « α », une modalité ligne « i » est placée au quasi-barycentre des modalités colonnes « j » qui la possèdent. Inversement, une modalité colonne « j » est placée au quasi-barycentre des modalités lignes « i » qui la possèdent.

2) *Une modalité ligne « i » attire d'autant plus la modalité colonne « j » que la part de « i » est grande dans « j ».*

Ces propriétés permettent d'interpréter la représentation simultanée des deux nuages (superposition). On peut ainsi interpréter la position d'une modalité ligne à partir des modalités colonnes et inversement, et établir les correspondances et répulsions ou oppositions. Et là se situe le principal intérêt de la représentation simultanée.

Mais les proximités peuvent conduire à des fausses interprétations, car la proximité d'une modalité « i » de « j » peut être due à des attractions diverses. Par conséquent, le seul endroit où il n'y a pas de risque d'erreur dans l'interprétation c'est le bord du nuage. Les résultats peuvent alors être commentés directement en observant les graphiques. On commentera les modalités situées au bord sans ambiguïté. Pour celles qui ne sont pas au bord, il est impératif, d'interpréter avec beaucoup de précaution. S'il y a risque de se tromper, il est préférable de ne pas les interpréter. Par ailleurs, la méthode réalise le test du khi deux que nous pouvons commenter.

IV.3. Exemple d'AFC

Illustrons par un exemple par un exemple (pédagogique). Une entreprise commerciale s'interroge sur les critères d'achat de son produit. Pour cela, elle a demandé à un échantillon de 207 personnes, ventilés en 4 groupes socioprofessionnels d'indiquer le critère qu'elles privilégient parmi 4 proposés. Le tableau de contingence issu des données recueillies est le suivant :

	catégorie socioprofessionnelle				
Critère	cadre	commerçant	employé	ouvrier	Total
aspect	16	20	12	12	60
parfum	17	15	6	7	45
prix	12	18	25	7	62
protection	10	14	8	8	40
Total	55	67	51	34	207

Notons que pour la réalisation de l'AFC sur Spad, on dispose au départ d'un tableau de données individuelles, et on construit le tableau de contingence en indiquant les variables (ligne et colonne) pendant le paramétrage.

Résultats

Le test du khi deux ci-dessous nous permet de conclure qu'au seuil de risque de 5%, il n'existe pas de liaison entre le critère d'appréciation et la catégorie socioprofessionnelle.

KHI2 = 14.90 / 9 DEGRES DE LIBERTE / 0 EFFECTIFS THEORIQUES INFERIEURS A 5 PROBA (KHI2 > 14.90) = **0.094** / V.TEST = 1.32

Cette « PROBA » est appelé sous d'autres logiciels « P. value » ou « Signification » et représente le risque de première espèce. On rejette l'hypothèse nulle dès lors que cette valeur est inférieure au seuil de risque. Sinon on ne la rejette pas.

i) L'histogramme des valeurs propres nous permet de voir qu'un seul axe en fait remplis les critères. Mais nous utilisons les deux premiers car il faut deux pour former un plan factoriel.

HISTOGRAMME DES 3 PREMIERES VALEURS PROPRES

NUMERO	VALEUR PROPRE	POURCENT.	POURCENT. CUMULE	
1	0.0639	88.74	88.74	*****
2	0.0080	11.09	99.83	*****
3	0.0001	0.17	100.00	*

ii) les contributions :

COORDONNEES, CONTRIBUTIONS DES FREQUENCES SUR LES AXES 1 A 3
FREQUENCES ACTIVES

FREQUENCES	COORDONNEES	CONTRIBUTIONS	COSINUS CARRES
------------	-------------	---------------	----------------

IDEN - LIBELLE COURT	P.REL	DISTO	1	2	3	0	0	1	2	3	0	0	1	2	3	0	0
cadre-	26.57	0.06	0.22	0.12	-0.01	0.00	0.00	20.0	44.6	8.8	0.0	0.0	0.78	0.22	0.00	0.00	0.00
commerçant	32.37	0.00	0.06	-0.03	0.02	0.00	0.00	2.0	3.3	62.4	0.0	0.0	0.79	0.16	0.05	0.00	0.00
employé	24.64	0.18	-0.43	0.02	0.00	0.00	0.00	70.9	1.0	3.5	0.0	0.0	1.00	0.00	0.00	0.00	0.00
ouvrier	16.43	0.05	0.17	-0.16	-0.01	0.00	0.00	7.1	51.1	25.3	0.0	0.0	0.53	0.47	0.00	0.00	0.00


COORDONNEES, CONTRIBUTIONS ET COSINUS CARRES DES INDIVIDUS
AXES 1 A 3

INDIVIDUS			COORDONNEES					CONTRIBUTIONS					COSINUS CARRES				
IDENTIFICATEUR	P.REL	DISTO	1	2	3	0	0	1	2	3	0	0	1	2	3	0	0
AA_1 : aspect	28.99	0.02	0.11	-0.07	-0.01	0.00	0.00	5.0	19.9	47.1	0.0	0.0	0.66	0.33	0.01	0.00	0.00
AA_2 : parfum	21.74	0.10	0.29	0.14	0.00	0.00	0.00	27.8	49.9	0.5	0.0	0.0	0.82	0.18	0.00	0.00	0.00
AA_3 : prix	29.95	0.14	-0.37	0.04	0.00	0.00	0.00	64.4	5.6	0.0	0.0	0.0	0.99	0.01	0.00	0.00	0.00
AA_4 : protection	19.32	0.02	0.10	-0.10	0.02	0.00	0.00	2.7	24.7	52.3	0.0	0.0	0.46	0.52	0.02	0.00	0.00

iii) Sur le premier axe, les modalités : employé, parfum et prix ont des CTR (contributions) qui excèdent leur poids. Ce sont donc ces modalités qui ont fixé l'axe. Par observation des signes des coordonnées de ces modalités sur l'axe 1, on constate une opposition entre ceux qui préfèrent le parfum et ceux qui sont regardant sur les prix.

Sur l'axe 2, les modalités qui ont de fortes contributions (supérieures au poids) sont : parfum et cadre. iv) Les modalités : cadre, employé, commerçant ainsi que aspect, parfum et prix sont bien représentés sur l'axe 1, et aucune modalité n'est bien représentée sur l'axe 2. Néanmoins, les modalités : protection et ouvrier sont bien représentées dans le plan. Toutes les modalités sont donc bien représentées dans le plan.

Mais comme signalé, le seul lieu où il n'y a pas de risque de fausses interprétations des attirances et répulsions c'est au bord du nuage. Le graphique laisse voir que les cadres privilégient le parfum, les employés sont regardants sur les prix, alors que les commerçants et ouvriers soit l'aspect, soit les capacités protectrices du produit (barycentre).



Remarques terminales sur l'AFC.

Comme en ACP, il est possible de faire figurer des variables ou des modalités de variables nominales en éléments supplémentaires. Ceux-ci ne participent pas à la formation des axes, mais s'y projettent afin d'illustrer certaines associations entre les modalités.

En outre, le fait que l'AFC n'étudie pas directement les tableaux de contingence bruts, mais les tableaux de profil rend cette méthode applicable à un ensemble plus vaste de tableaux qui ne sont pas nécessairement des tableaux de contingence. De façon générale, l'AFC s'applique aux tableaux croisés dont les sommes en lignes et en colonnes ont un sens. Le lecteur pourra consulter BRY (1995) pour en savoir davantage.

Chap. V. ANALYSE FACTORIELLE DES CORRESPONDANCES MULTIPLES (ACM)

Introduction

L'AFC peut se généraliser de plusieurs manières dans le cas où non plus deux variables sont mises en correspondance, mais deux ensembles de variables. La généralisation la plus simple et la plus employée est l'analyse des correspondances multiples (ACM).

V.1. Les domaines d'application

Elle permet donc l'étude des liaisons entre plus de deux variables qualitatives, ce qui étend le spectre d'étude de l'AFC.

L'ACM est donc très bien adaptée au traitement d'enquêtes lorsque les variables sont qualitatives (ou rendues qualitatives).

V.2. Les données

L'ACM permet l'étude de tableaux décrivant une population de I individus et J variables qualitatives. Une variable qualitative (ou nominale) peut être décrite par une application de l'ensemble des I individus dans un ensemble fini non structuré, par exemple non ordonné. Ces variables qualitatives peuvent être codées par un codage condensé qui attribue une valeur à chaque modalité. Par exemple les modalités pour la couleur d'un vin peuvent être 1 pour le rouge, 2 pour le blanc et 3 pour le rose. Les données peuvent donc être représentées sous la forme d'une matrice X décrite par le tableau 1.1, où I représente à la fois le nombre d'individus et l'ensemble des individus $I = \{1, \dots, I\}$, J représente à la fois le nombre de variables et l'ensemble des variables $J = \{1, \dots, J\}$, x_{ij} le codage condensé de l'individu i pour la variable j

		VARIABLES	
		1.....j.....J	
INDIVIDUS	1		
	⋮		
	i		x_{ij}
	⋮		
	I		
	⋮		

Tableau 1.1 : Représentation des données sous forme condensée pour l'ACM

Les x_{ij} représentant une codification, en prendre la moyenne n'a aucun sens. Ces données ne peuvent donc pas être traitées par l'ACP ou l'AFC.

Ce tableau présente donc des spécificités dont l'analyse factorielle doit tenir compte par une méthode spécifique.

V.3. Les objectifs

Les objectifs de l'ACM sont les mêmes que ceux de l'ACP ou de l'AFC. Il s'agit d'obtenir une typologie des lignes et des colonnes et relier ces deux typologies. Nous aurons ici trois familles d'éléments à étudier, les individus, les variables et les modalités des variables. Cette étude se fait par la définition de ressemblances et liaisons pour ces trois familles. Afin d'établir un bilan des ressemblances entre individus, comme en ACP nous cherchons à répondre à des questions du type :

- Quels sont les individus qui se ressemblent ?
- Quelles sont ceux qui sont différents ?
- Existe-t-il des groupes homogènes d'individus ?
- Est-il possible de mettre en évidence une typologie des individus ?

Les mêmes types de questions se posent pour les variables et les modalités.

V.4. Principe de l'ACM

Le principe de base de l'ACM repose dans un premier temps sur une transformation des données du tableau pour modifier la codification en nombres binaires. L'analyse applique ensuite le même principe que l'AFC, sur ce tableau disjonctif complet. La distance du χ^2 est également employée pour définir les liaisons.

		Variable1 ... Variable j ... Variable J																																																			
		1.....1...k.....Kj.....K																																																			
Individus	1	<table> <tr><td></td><td></td><td></td><td></td><td></td></tr> <tr><td></td><td></td><td></td><td></td><td></td></tr> <tr><td></td><td></td><td></td><td></td><td></td></tr> <tr><td></td><td></td><td></td><td></td><td></td></tr> <tr><td></td><td></td><td></td><td></td><td></td></tr> </table>																										<table> <tr><td></td><td></td><td></td><td></td><td></td></tr> <tr><td></td><td></td><td></td><td></td><td></td></tr> <tr><td></td><td></td><td></td><td></td><td></td></tr> <tr><td></td><td></td><td></td><td></td><td></td></tr> <tr><td></td><td></td><td></td><td></td><td></td></tr> </table>																									
⋮																																																					
i	•	0100000	$\mathbf{x_{ik}}$	0000100																																																	
⋮																																																					
1	•																																																				

I ₁	I _k	I _K	I _J
----------------	----------------	----------------	----------------

Tableau 1.2 : Représentation des données sous forme disjonctive complète

V.5. La transformation des données

Une autre représentation du tableau 1.1 est le tableau disjonctif complet. Il représente les individus en ligne, alors que les colonnes représentent les modalités des variables (et non plus les variables) (cf. tableau 1.2). Ainsi, à l'intersection de la ligne i avec la colonne k , la valeur x_{ik} vaut 1 si l'individu i possède la modalité k et 0 sinon. Ce tableau porte le nom de disjonctif complet, car l'ensemble des valeurs x_{ik} d'un même individu pour les modalités d'une même variable, comporte la valeur 1 une fois (complet) et une fois seulement (disjonctif). Chaque modalité k est reliée à une variable j .

Notons K_j le nombre des modalités de la variable j et également l'ensemble des modalités de cette variable $K_j = \{1, \dots, K_j\}$. Ainsi $K = \sum_{j \in J} K_j$ est à la fois le nombre des modalités toutes variables confondues et l'ensemble $K = \{1, \dots, K\}$. Nous avons donc les égalités suivantes :

$$\sum_{k \in K_j} x_{ik} = 1, \forall (i, j), \quad (1)$$

$$\sum_{k \in K} x_{ik} = J, \forall i, \quad (2)$$

$$\sum_{i \in I} x_{ik} = I_k, \forall k \quad (3)$$

$$\sum_{k \in K_j} I_k = I, \forall j, \quad (4)$$

	Couleur	Origine	Appréciation
Individu 1	2	1	4
Individu 2	2	1	3
Individu 3	2	2	1
Individu 4	3	2	3
Individu 5	1	1	2
Individu 6	3	1	2
Individu 7	3	2	1
Individu 8	1	2	3


Tableau 1.3 - Exemple du vin : tableau initial

Les propriétés intéressantes de l'ACM sont essentiellement dues aux propriétés des tableaux disjonctifs complets. Notons surtout que c'est un tableau binaire dont les lignes sont de sommes constantes à J et dont les colonnes sont regroupées par paquet correspondant à une variable avec pour somme par ligne égale à 1.

Pour une meilleure compréhension de cette transformation, nous pouvons l'illustrer par un exemple. Nous supposons avoir des données issues d'une enquête sur l'appréciation du vin. Nous pouvons considérer trois variables : la couleur, l'origine et l'appréciation de l'individu. Nous considérons les trois modalités rouge, blanc et rosé pour la couleur codées respectivement par 1, 2 et 3. Nous considérons uniquement deux origines : Bordeaux et Côte du Rhône, codées par 1 et 2, et quatre modalités pour l'appréciation : mauvais, moyen, bon et très bon codées respectivement par 1, 2, 3 et 4. Nous avons ainsi trois variables ($J = 3$) et neuf modalités ($K = 9$). Les résultats de l'enquête fictive sont donnés dans le tableau 5.3. Ainsi, par exemple l'individu 5 a moyennement apprécié un Bordeaux rouge. Le tableau disjonctif complet 5.4 déduit de ce tableau initial présente les mêmes informations. Ainsi, l'individu 5 présente les modalités : rouge, Bordeaux, moyen.

Lorsque le nombre de variables est réduit à deux ($J = 2$), les données peuvent être représentées sous la forme d'un tableau de contingence, comme dans l'AFC, mettant ainsi en correspondance les modalités des deux variables. Il est possible d'étendre ce tableau à une hypertexte de contingence lorsque $J = 3$, où K_1 (respectivement K_2 et K_3) représente le nombre de modalités de la première (respectivement deuxième et troisième) variable et I_{klm} est le nombre d'individus possédant les modalités k (de la première variable), l (de la deuxième variable) et m (de la troisième variable). Cependant dès que J augmente le nombre de cases devient très important et l'hypertexte est alors difficile à manier et à représenter.

	Couleur			Origine		Appréciation			
	Rouge	Blanc	Rosé	Bordeau x	Côtes de Rhône	Mauvais	Moye n	Bon	Très bon
Ind. 1	0	1	0	1	0	0	0	0	1
Ind. 2	0	1	0	1	0	0	0	1	0
Ind. 3	0	1	0	0	1	1	0	0	0
Ind. 4	0	0	1	0	1	0	0	1	0
Ind. 5	1	0	0	1	0	0	1	0	0
Ind. 6	0	0	1	1	0	0	1	0	0
Ind. 7	0	0	1	0	1	1	0	0	0
Ind. 8	1	0	0	0	1	0	0	1	0

Tableau 1.4 - Exemple du vin : tableau disjonctif complet.**Fig. 1.1 : Hypertable de contingence pour J = 3.**

L'hypertable étant problématique pour un grand nombre de variables, pour généraliser le tableau de contingence à deux variables, il est possible de considérer les tableaux de contingence entre variables prises deux à deux. Nous obtenons ainsi une juxtaposition de tableaux de contingence. Un tel tableau est appelé tableau de Burt du nom de son auteur (c.f. tableau 1.5).

		Couleur			Origine		Appréciation			
		Rouge	Blanc	Rosé	Bordeaux	Côtes de Rhône	Mauvais	Moyen	Bon	Très bon
Couleur	Rouge	2	0	0	1	1	0	1	1	0
	Blanc	0	3	0	2	1	1	0	1	1
	Rosé	0	0	3	1	2	1	1	1	0
Origine	Bordeaux	1	2	1	4	0	0	2	1	1
	Côtes de Rhône	1	1	2	0	4	2	0	2	0
Appréciation	Mauvais	0	1	1	0	2	2	0	0	0
	Moyen	1	0	1	2	0	0	2	0	0
	Bon	1	1	1	1	2	0	0	3	0
	Très bon	0	1	0	1	0	0	0	0	1

Tableau 1.5 - Exemple du vin : tableau de Burt.

Comme en ACP nous cherchons une typologie des individus. La notion de ressemblance est déterminée par le nombre de modalités en commun. Par exemple dans une enquête d'opinion, il est important de mettre en évidence une classe d'individus déterminée par des variables. Pour l'étude des variables deux points de vue s'offrent à nous. Nous pouvons caractériser les liaisons entre deux variables qualitatives en considérant les modalités, ou encore chercher à résumer l'ensemble des liaisons à l'aide de quelques variables numériques qui synthétisent l'ensemble des variables. Les catégories socio-professionnelles peuvent ainsi résumer une variable "statut social". La richesse de l'ACM provient de l'étude d'une troisième classe d'éléments, les modalités. De la même façon que les individus, nous pouvons chercher à établir un bilan des ressemblances entre modalités. Les

ressemblances entre modalités peuvent être définies à partir du tableau disjonctif complet, ou bien à partir du tableau de Burt. Dans le premier cas une colonne est une variable indicatrice, ainsi deux modalités se ressemblent si elles sont présentes ou absentes chez beaucoup d'individus. Dans le cas du tableau de Burt, une ligne ou une colonne correspond à une classe d'individus, ainsi deux modalités se ressemblent si elles s'associent beaucoup ou peu aux mêmes modalités. Ces deux points de vue aboutissent aux mêmes résultats. L'ACM peut donc être vue comme une AFC du tableau disjonctif complet ou comme une AFC du tableau de Burt.

La richesse apportée par ces trois éléments, ne doit pas occulter l'unicité du tableau, et donc des conclusions parfois redondantes. Il sera donc préféré l'étude des modalités en priorité.

V.6. Les variables quantitatives

Initialement prévue pour les variables qualitatives, l'ACM peut traiter également les variables quantitatives, sous condition qu'elles soient rendues qualitatives. Ceci a un double intérêt. Tout d'abord, rendre des variables quantitatives en variables qualitatives permet d'obtenir un tableau homogène et ainsi d'analyser l'ensemble de ces variables par une même analyse. Un autre intérêt est qu'une ACM sur des variables quantitatives codées en classe peut mettre en évidence des liaisons entre variables non linéaires, que l'ACP ne peut dévoiler. Or les liaisons non linéaires sont très fréquentes en pratique.

V.7. Les éléments d'aide à l'interprétation

L'interprétation d'une ACM diffère quelque peu de celle d'une AFC :

- deux modalités d'une même variable ne peuvent avoir le même profil ;
- deux modalités possédées par les mêmes individus sont confondus, et une modalité se situe au quasi barycentre des individus et des modalités qui la possèdent ;
- les modalités rares sont éloignées de toutes les autres modalités. En effet, on démontre que la distance d'une modalité j au centre de gravité est $\left(\frac{n}{n_j}\right) - 1$ où n_j est le nombre d'individus présentant la modalité j . Ainsi, plus n_j est grand, plus le profil de la modalité ressemble au profil moyen, et la modalité est proche du centre de gravité. Par contre, une modalité rare est éloignée du centre de gravité, et a des fortes contributions.

Pour le reste, on utilise les mêmes éléments d'aide à l'interprétation qu'en AFC : les contributions (CTR) et les COS2. Toutefois, les valeurs propres et les taux d'inerties n'ont pas la même interprétation statistique. En effet, l'inertie totale d'une AFC sur tableau disjonctif complet n'est pas liée à la structure intrinsèque du tableau, c'est-à-dire aux liaisons entre les variables. L'inertie dépend uniquement du nombre de modalités et du nombre de variables (actives). Du fait de la nature disjonctive du tableau, les taux d'inertie sont très faibles et donnent une image pessimiste de l'importance des facteurs. En outre, les valeurs propres tendent à décroître de façon régulière, ce qui rend délicate l'étude de l'histogramme des valeurs propres.

Utilisation des contributions (CTR)

La CTR d'une modalité j est égale $CTR(j) = (1 - \frac{n_j}{n})/J$. Les modalités à faibles fréquences influencent donc le plus. Il est alors souhaitable, au moment de la codification, de veiller autant que possible à ce qu'il n'y ait pas de modalités rares.

On démontre que la contribution d'une variable est proportionnelle au nombre de ses modalités $CTR(X_j) = \frac{1}{p}(m(X_j) - 1)$ où $m(X_j)$ est le nombre de modalités possibles de X_j . Par conséquent, si l'on souhaite que les variables aient à peu près la même importance dans l'analyse, il est aussi préférable que chaque variable est à peu près le même nombre de modalités. On repère les variables qui participent à la définition des axes à partir des modalités à fortes contributions.

Utilisation des COS2

Il représente la qualité de représentation des points et permet de repérer les proximités illusoires.

Pour les individus et les modalités bien représentés, on a les interprétations suivantes :

Deux individus proches se ressemblent, c'est-à-dire qu'ils ont choisi les mêmes modalités. Mais l'interprétation de la proximité entre modalités de différentes variables est un peu délicate ; on peut simplement dire que les individus possédant l'une des modalités ont le même centre de gravité que ceux possédant l'autre modalité.

V.8. Règles et démarche pour l'Interprétation d'une ACM

Comme signalé, l'interprétation d'une ACM diffère quelque peu de celle d'une AFC :

- Deux modalités d'une même variable ne peuvent avoir le même profil ;
- Deux modalités possédées par les mêmes individus sont confondues, et une modalité se situe au quasi barycentre des individus et des modalités qui la possèdent ;
- Les modalités rares sont éloignées de toutes les autres modalités. En effet, on démontre que la distance d'une modalité j au centre de gravité g_0 est $(N/N_j)-1$, où N_j est le nombre d'individus présentant la modalité j . Ainsi, plus N_j est grand, plus le profil de la modalité ressemble au profil moyen, et la modalité est proche du centre de gravité. Par contre, une modalité rare est éloignée du centre de gravité, et a des fortes contributions, donc fixe les axes.

Pour le reste, on utilise les mêmes éléments d'aide à l'interprétation qu'en AFC : les CTR et les COS2. Toutefois, les valeurs propres et les taux d'inerties n'ont pas la même interprétation statistique. En effet, l'inertie totale d'une AFC sur tableau disjonctif complet n'est pas liée à la structure intrinsèque du tableau, c'est à dire aux liaisons entre les variables. L'inertie dépend uniquement du nombre de modalités et du nombre de variables actives. Du fait de la nature disjonctive du tableau, les taux d'inertie sont très faibles et donnent une image pessimiste de l'importance des facteurs. En outre, les valeurs propres tendent à décroître de façon régulière, ce qui rend délicate l'étude de l'histogramme des valeurs propres.

Utilisation des contributions (CTR)

La CTR d'une modalité j est égale à $CTR(j) = (1-N_j/N)/P$. les modalités à faibles fréquences influencent donc le plus. Il est donc souhaitable, au moment de la codification, de veiller autant que possible à ce qu'il n'y ait pas de modalités rares.

On démontre aussi que la contribution d'une variable est proportionnelle au nombre de ses modalités. Par conséquent, si l'on souhaite que les variables aient à peu près la même importance dans l'analyse, il est aussi préférable que chaque variable est à peu près le même nombre de modalités. On repère les variables qui participent à la définition des axes à partir des modalités à fortes contributions.

Utilisation des COS2

Il représente la qualité de représentation des points et permet de repérer les proximités illusoires. Pour les individus et les modalités bien représentés, on a les interprétations suivantes : Deux individus proches se ressemblent, c'est à dire qu'ils ont choisi les mêmes modalités ; L'interprétation de la proximité entre modalités de différentes variables est un peu délicate ; on peut simplement dire que les individus possédant l'une des modalités ont le même centre de gravité que ceux possédant l'autre modalité.

L'analyse pour l'interprétation pourra suivre les étapes suivantes :

- i) Interpréter la répartition par modalité de chaque variable, qui est donnée « Poids ».
- ii) Déterminer le nombre d'axes à retenir ;
- ii) Identifier les points ayant de fortes CTR sur les axes (même principe qu'en AFC) et donner le sens des axes.
- v) Interpréter les plans factoriels. Dans la pratique on s'intéresse d'abord au premier plan factoriel sur lequel on commente sans ambiguïté les correspondances et oppositions au « bord » du nuage.

Les proximités observées à « l'intérieur du nuage » (c'est-à-dire hors du bord) doivent être confirmée sur plusieurs plans à interpréter. On parcourt donc les autres plans factoriels en croisant (2 à 2) les axes retenus. A chaque fois, on commente au bord uniquement les phénomènes nouveaux (non observés dans les plans précédents), et on recherche la confirmation des proximités identifiées à l'intérieur du nuage.

V.9. Exemple d'ACM

Nous utilisons les mêmes données que celles qui ont permis de réaliser l'AFC. Mais en plus on dispose du sexe et des revenus des individus. Les revenus ont été « codé » en 4 modalités : très pauvre de 0 à 49 000 F, pauvre de 50 000 F à 99000, niveau de vie moyen de 100 000 F à 249 000 F, et riche à partir de 250 000 F.

SOMME DES VALEURS PROPRES 2.5000

HISTOGRAMME DES 10 PREMIERES VALEURS PROPRES

NUMERO	VALEUR PROPRE	POURCENT.	POURCENT. CUMULE
1	0.4725	18.90	18.90
2	0.4171	16.68	35.59
3	0.3075	12.30	47.89
4	0.2909	11.64	59.52
5	0.2829	11.32	70.84
6	0.2332	9.33	80.17
7	0.1947	7.79	87.96
8	0.1514	6.06	94.01
9	0.1050	4.20	98.21
10	0.0447	1.79	100.00

L'histogramme des valeurs propres nous suggère de retenir quatre ou cinq premiers axes. En effet, à l'axe 4, on a un cumul de 59,59% de l'inertie (ce qui statistiquement n'est pas différent de 60%). Par ailleurs, on des coudes aux 2^{ème} (mais là on est loin de 60% d'inertie) et 5^{ème} axes (on a dépassé 60%, ce qui n'est pas mauvais, au contraire). De plus, la valeur moyenne est (somme des valeurs propres) / (nombre de valeurs propres), soit $2,5/10 = 0,25$. Les axes dont les valeurs propres sont supérieures à 0,25 sont donc importants. Ce qui conduit encore à retenir les 5 premiers axes. Finalement, il est préférable de retenir 5 axes, que l'on croiera 2 à 2.

Nous nous intéressons uniquement au plan factoriel principal comme exemple de commentaires⁶. Les modalités ayant fortement contribué au positionnement des axes 1 et 2 sont celles dont les contributions excèdent les poids. Elles expliquent ces axes. Sur l'axe 1, on a cadre, employé, ouvrier, et toutes les variables de niveau de vie (sauf niveau moyen).

COORDONNEES, CONTRIBUTIONS ET COSINUS CARRES DES MODALITES ACTIVES
AXES 1 A 5

MODALITES				COORDONNEES					CONTRIBUTIONS					COSINUS CARRES				
IDEN - LIBELLE	P.REL	DISTO		1	2	3	4	5	1	2	3	4	5	1	2	3	4	5
1 . Critère																		
AA_1 - C2=aspect	7.25	2.45		0.20	0.39	0.13	0.01	-0.90	0.6	2.6	0.4	0.0	20.6	0.02	0.06	0.01	0.00	0.33
AA_2 - C2=parfum	5.43	3.60		-0.57	-0.19	-0.68	1.19	-0.31	3.8	0.5	8.1	26.3	1.9	0.09	0.01	0.13	0.39	0.03
AA_3 - C2=prix	7.49	2.34		0.47	-0.19	-0.44	-0.96	0.42	3.4	0.6	4.8	23.7	4.7	0.09	0.02	0.08	0.39	0.08
AA_4 - C2=protection	4.83	4.18		-0.37	-0.08	1.25	0.13	1.04	1.4	0.1	24.6	0.3	18.6	0.03	0.00	0.37	0.00	0.26
CONTRIBUTION CUMULEE = 9.2 3.8 37.9 50.3 45.7																		
2 . sexe																		
AB_1 - C3=fem	9.90	1.52		-0.36	-0.85	-0.43	0.27	-0.18	2.7	17.0	5.9	2.4	1.1	0.08	0.47	0.12	0.05	0.02
AB_2 - C3=masc	15.10	0.66		0.23	0.55	0.28	-0.18	0.12	1.8	11.1	3.9	1.6	0.8	0.08	0.47	0.12	0.05	0.02
CONTRIBUTION CUMULEE = 4.4 28.1 9.8 4.1 1.9																		
3 . catégorie socio																		
AC_1 - C4=cadre	6.64	2.76		-1.14	0.96	-0.31	-0.23	0.16	18.3	14.7	2.1	1.2	0.6	0.47	0.33	0.03	0.02	0.01
AC_2 - C4=commerçant	8.09	2.09		-0.34	-0.96	0.44	-0.05	-0.51	2.0	18.0	5.2	0.1	7.3	0.05	0.45	0.09	0.00	0.12
AC_3 - C4=employé	6.16	3.06		0.88	-0.35	-0.88	-0.20	0.75	10.1	1.8	15.6	0.8	12.4	0.25	0.04	0.25	0.01	0.19
AC_4 - C4=ouvrier	4.11	5.09		1.19	0.87	0.95	0.77	-0.39	12.4	7.4	11.9	8.4	2.2	0.28	0.15	0.18	0.12	0.03
CONTRIBUTION CUMULEE = 42.8 42.0 34.8 10.6 22.5																		
5 . Niveau de vie																		
AD_1 - C6=niveau moyen	7.61	2.29		-0.63	-0.72	0.64	-0.06	0.44	6.4	9.6	10.2	0.1	5.2	0.17	0.23	0.18	0.00	0.09
AD_2 - C6=pauvre	7.13	2.51		0.99	0.17	-0.34	0.89	0.39	14.7	0.5	2.7	19.2	3.9	0.39	0.01	0.05	0.31	0.06
AD_3 - C6=riche	5.19	3.81		-1.20	1.10	-0.52	-0.22	-0.14	15.9	15.1	4.6	0.9	0.4	0.38	0.32	0.07	0.01	0.01
AD_4 - C6=très pauvre	5.07	3.93		0.79	-0.28	0.05	-0.92	-1.07	6.6	1.0	0.0	14.9	20.4	0.16	0.02	0.00	0.22	0.29
CONTRIBUTION CUMULEE = 43.6 26.1 17.5 35.1 29.9																		


Interprétation de l'axe 1 : Les modalités dont les contributions sont fortes et excèdent les poids sont : cadre, employé, ouvrier, pauvre et riche. Les signes des coordonnées laissent ressortir que l'axe 1 oppose : Les riches aux pauvres ; Les cadres aux ouvriers et employés.

Le lecteur pourra essayer de retrouver le sens des autres axes.

⁶ En principe, on devrait former et commenter tous les plans formés par les 5 axes retenus. Mais pratiquement, on progresse du plan le plus important vers les autres, en commentant à chaque fois les phénomènes nouveaux.

De façon pratique, on commente les phénomènes au bord du nuage dans le graphique. Ainsi, on constate une association entre *cadre* et *riche*, entre *employé* et *très pauvre* et entre niveau moyen, fem et commerçant. Donc, en général, les cadres sont riches, les employés très pauvres et les femmes sont des commerçantes et ont un revenu moyen. Les individus concernés par la première typologie sont : 157, 144, 143, 173, 128, 162, 172, 167, 166, 165, 161. la modalité *pauvre* aussi est bien représentée, et les individus concernés sont par exemple : 24 et 178, 34, 31. nous laissons au lecteur la suite des commentaires.

Facteur 2



Conclusion

L'ACM est donc une analyse factorielle qui permet l'étude de plusieurs variables qualitatives, de ce fait elle est une généralisation de l'AFC. Elle est donc applicable aux tableaux de variables qualitatives, mais aussi quantitatives après construction de classes à partir de celles-ci. Le fait de pouvoir interpréter l'ACM de plusieurs façons rend cette méthode très riche et d'emploi facile. Elle peut être très complémentaire de l'ACP et bien sûr des méthodes de classification.

Les méthodes de classification permettent de regrouper les individus en classes selon leurs ressemblances. Deux types d'approches sont possibles soit nous considérons des données sur lesquelles nous connaissons les différentes classes et nous tentons d'affecter un nouvel individu dans une des classes connues, soit nous n'avons aucun a priori sur les classes. Nous allons étudier ces deux types de classification dans les chapitres suivants.

Chap. VI. INTRODUCTION A LA CLASSIFICATION AUTOMATIQUE

La classification automatique, à la suite d'une analyse factorielle permet de répartir les individus d'une population en sous-groupes homogènes.

VI.1. Objet et méthodes de classification

a) Objet de la classification automatique

Les méthodes de classification automatique cherchent à structurer un ensemble d'individus (éventuellement massif) en sous-ensembles cohérents appelés classes. Il s'agit donc de réaliser une partition de l'ensemble de ces individus en groupes selon ce qu'ils ont en commun. Les classes sont formées de sorte à ce qu'à l'intérieur d'une classe, les individus soient homogènes et, deux classes sont hétérogènes. Ainsi, aucun individu extérieur à une classe ne doit posséder toutes les caractéristiques de cette classe.

A priori, il n'y a pas un nombre standard de classes à constituer, tout dépend de la structure intrinsèque du tableau des données. Le nombre de classes peut être suggéré par la configuration des individus sur les plans factoriels. Toutefois, si les données présentent des classes « naturelles », le but de la classification sera de les déterminer. Dans le cas contraire, il peut exister plusieurs choix du nombre de classes à constituer, et il appartient au statisticien de faire un choix, en fonction des exigences d'homogénéité qui s'imposent. Ce dernier pourra indiquer le nombre de classes qui l'intéresse suivant l'objectif recherché, ou alors opérer un choix parmi les propositions du logiciel.

Ces méthodes sont fréquemment utilisées pour la segmentation de la clientèle (banque par exemple), la taxonomie et le diagnostic automatisé, la confection des strates pour sondages, etc.

b) Principe des méthodes

Puisqu'il s'agit de construire des groupes d'individus qui se ressemblent, il faut définir des critères de ressemblance. Il existe une grande variété de méthodes à ce sujet⁷. Il n'existe pas de méthode parfaite. Une méthode est choisie dans une optique, et il est parfois préférable d'utiliser plusieurs méthodes et de comparer les classes obtenues pour choisir la meilleure partition.

Nous nous intéresserons aux méthodes dites de *classification ascendante hiérarchique* (CAH). Elles sont toujours précédées d'une analyse factorielle (ACP, AFC ou ACM) car elles utilisent les coordonnées factorielles des individus, et non les données brutes. Pour cette raison, on les appelle encore *classification sur facteurs*.

Le critère d'appréciation de la ressemblance entre individus est l'inertie, comme en analyse factorielle. De façon générale, pour agréger plusieurs individus en une classe, il faut oublier toutes les différences entre ceux-ci. Chaque classe possède une inertie interne, qui est l'inertie des individus de la classe par rapport leur centre de gravité. Le principe est de minimiser l'inertie interne des classes, et de maximiser l'inertie entre les centres de gravités des différentes classes.

VI.2. Etapes pour la réalisation d'une classification sur facteurs

Il faut d'abord suivre toutes les étapes requises pour réaliser une analyse factorielle. Cependant, au moment du paramétrage, indiquer rigoureusement le nombre de coordonnées factorielles à conserver. Ce sont ces coordonnées (facteurs) qui seront utilisées pour la classification (n'oublions pas que nous présentons une classification sur facteurs). Au besoin, conserver toutes les coordonnées, ou alors indiquer ce nombre après avoir observé l'histogramme des valeurs propres ; retenir le nombre d'axes satisfaisant pour l'analyse, mais alors il y aura perte d'informations consécutive aux axes laissés.

A la suite de l'analyse factorielle, on en arrive à une étape 5 :

⁷ Le lecteur qui veut une étude poussée pourra consulter le document de Bry Z. *Introduction à l'analyse factorielle et à la classification*

Etape 5 : Toujours dans la même filière de l'analyse factorielle, insérer une nouvelle icône pour une méthode, et y déposer la méthode « *classification sur facteurs* » du groupe des méthodes de classification. Paramétrer la et exécuter la.

Etape 6 : Toujours dans la même filière, insérer encore une nouvelle icône pour une méthode, et y déposer cette fois la méthode « *coupure de l'arbre et description des classes* » du groupe des méthodes de classification. Paramétrer la en indiquant le nombre de classes et les éléments à utiliser pour caractériser les classes (continues, modalités ...). Exécutez ensuite la méthode, et visualisez les classes et caractérisez-les.

VI.3. Caractérisation des classes

Après la classification, il faut caractériser les classes par les individus et les variables ou leurs modalités. Tout dépend de l'analyse factorielle qui a précédé la classification. Lorsque la classification est opérée à la suite d'une ACP, la caractérisation se fait par les variables, et éventuellement les modalités des variables qualitatives (introduites pour illustrer). Mais à la suite analyse factorielle sur caractères qualitatifs, la caractérisation se fait essentiellement par les modalités.

a) Caractérisation par les valeurs tests

Pour les variables nominales, on compare à l'aide du khi deux, les profils de la variable dans la classe au profil global sur la population totale. En pratique, on utilise la valeur test pour mesurer statistiquement la dépendance ou la liaison entre variables (nominales ou continues) et les classes. Cette valeur test permet de trier par ordre d'importance les modalités et les variables les plus caractéristiques d'une classe. Une variable ou une modalité sera d'autant plus intéressante pour une classe que la valeur test correspondante sera significative, c'est à dire supérieure à 2 en valeur absolue pour le seuil de risque de 5%.

b) Caractérisation par les moyennes et les écarts types

Dans le cas où des variables quantitatives sont utilisées, l'idée la plus simple consiste à comparer les moyennes et les dispersions des variables relatives à chaque classe avec leurs moyennes et les dispersions générales calculées sur l'ensemble de la population, pour ce qui est des variables quantitatives. Ces indicateurs (moyenne et écart type) sont utilisés pour caractériser les classes. Les valeurs test dans ce cas indiquent les variables significatives.

c) Autres indicateurs

Deux autres indicateurs peuvent être utilisés pour caractériser les classes par les modalités des variables qualitatives⁸ : les MOD/CLA et les CLA/MOD. Les valeurs tests indiquent encore les modalités significatives.

Le MOD/CLA représente le pourcentage des individus présentant une modalité dans une classe. Il permet de voir les modalités les plus représentées parmi les modalités caractéristiques d'une classe. Si MOD/CLA = 90%, cela signifie que 90% des individus de la classe ont la modalité correspondante. Pour obtenir ces indicateurs, il faut l'activer (le choisir) lors du paramétrage.

Le CLA/MOD indique le pourcentage des individus de la classe qui possèdent la modalité. Cet indicateur permet de typer la classe à partir des modalités bien représentées dans la classe, et très peu représentées dans les autres classes. Par exemple, si CLA/MOD = 85%, cela signifie que 85% des individus ayant cette modalité sont dans cette classe. Cet indicateur s'active aussi pendant le paramétrage.

La caractérisation des classes consistera donc à la détermination des variables et modalités significatives, ainsi qu'au commentaires des MOD/CLA et CLA/MOD élevés (ou dans certains cas très faibles), ainsi qu'au commentaires des khi deux, dans le cas d'une caractérisation par les modalités. Dans le cas des caractérisations par les continues, on commentera les moyennes et écarts types des variables pertinentes.

⁸ Ce qui concerne essentiellement les classifications à la suite d'une AFC ou d'une ACM.

VI.4. Exemples d'applications

Nous illustrons uniquement à des fins pédagogiques, la classification par deux exemples, dont le premier est une classification réalisée à la suite d'une ACP du chapitre III, et la seconde à la suite d'une ACM du chapitre V.

1^{er} exemple : Classification à la suite de l'ACP du chapitre III

En rappel, on avait dans cette ACP une de la population de 12 employés d'une entreprise, et le principal critère discriminant était la richesse qui s'opposait à la taille du ménage. Ce qui suggère une partition des employés en deux groupes.

CARACTERISATION PAR LES MODALITES DES CLASSES OU MODALITES

DE COUPURE 'a' DE L'ARBRE EN 2 CLASSES

CLASSE 1 / 2

V.TEST	PROBA	POURCENTAGES	MODALITES	IDEN	POIDS
CLA/MOD	MOD/CLA	GLOBAL	CARACTERISTIQUES	DES VARIABLES	
-2.87	0.002	0.00	0.00	66.67 CLASSE 1 / 2	aala 8
			33.33 C6=superieur	Niveau d'inst	AA_3 4 -

CLASSE 2 / 2

V.TEST	PROBA	POURCENTAGES	MODALITES	IDEN	POIDS
CLA/MOD	MOD/CLA	GLOBAL	CARACTERISTIQUES	DES VARIABLES	
2.87	0.002	100.00	100.00	33.33 CLASSE 2 / 2	aa2a 4
			33.33 C6=superieur	Niveau d'inst	AA_3 4 --

CARACTERISATION PAR LES CONTINUES DES CLASSES OU MODALITES

DE COUPURE 'a' DE L'ARBRE EN 2 CLASSES

CLASSE 1 / 2

V.TEST	PROBA	MOYENNES	ECARTS TYPES	VARIABLES CARACTERISTIQUES	IDEN
		CLASSE GENERALE	CLASSE GENERAL	NUM.LIBELLE	
		CLASSE 1 / 2	(POIDS = 8.00	EFFECTIF = 8)	aala
2.91	0.002	5.75	4.67	0.97 1.75	3.Taille ménage C4
-2.54	0.006	54.88	69.08	17.01 26.28	2.Dep cons(*1000) C3
-3.10	0.001	61.88	91.25	18.86 44.49	1.Revenu(*1000) C2

CLASSE 2 / 2

V.TEST	PROBA	MOYENNES	ECARTS TYPES	VARIABLES CARACTERISTIQUES	IDEN
		CLASSE GENERALE	CLASSE GENERAL	NUM.LIBELLE	
		CLASSE 2 / 2	(POIDS = 4.00	EFFECTIF = 4)	aa2a
3.10	0.001	150.00	91.25	7.07 44.49	1.Revenu(*1000) C2
2.54	0.006	97.50	69.08	16.77 26.28	2.Dep cons(*1000) C3
-2.91	0.002	2.50	4.67	0.50 1.75	3.Taille ménage C4

On constate tout d'abord que toutes les valeurs tests sont supérieures à 2 en valeur absolue (seules les variables et modalités significatives sont donc représentées). Pour la caractérisation par les modalités de la variable qualitative « niveau d'instruction », on constate que le 1^{er} groupe composé des 2/3 de la population (soit 8 personnes) est constitué de ceux qui n'ont pas atteint le niveau supérieur dans leur formation, alors que le second groupe est composé des 4 employés qui y sont parvenues.

La caractérisation par les variables permet de comprendre que le premier groupe est celui des pauvres vivant dans des ménages de grande taille. En effet, le revenu moyen dans cette classe est de 61 880 (les valeurs sont en milliers), et est de loin inférieur au revenu moyen général (91 250). Leurs dépenses sont aussi inférieures aux dépenses générales, en moyenne, alors que les tailles de leurs ménages sont en moyenne supérieures à la moyenne. Les écarts types dans la classe sont tous inférieurs à ceux de la population globale, ce qui permet de penser que les moyennes sont bien représentatives du niveau individuel.

Le 2^{ème} groupe a toutes les caractéristiques opposées : des revenus et dépenses de consommation en moyennes supérieurs aux niveaux généraux, et des ménages de taille moyenne proche de la moitié du niveau général. Les écarts types étant tous inférieurs à ceux de toute la population démontre que ces moyennes sont significatives.

2^{ème} exemple : Classification à la suite de l'ACM du chapitre V

CARACTERISATION PAR LES MODALITES DES CLASSES OU MODALITES

DE COUPURE 'a' DE L'ARBRE EN 4 CLASSES

CLASSE 1 / 4

V.TEST	PROBA	POURCENTAGES	MODALITES	IDEN	POIDS
CLA/MOD	MOD/CLA	GLOBAL	CARACTERISTIQUES	DES VARIABLES	

CLASSE 1 / 4										aa1a		70
13.58	0.000	95.52	91.43	32.37	C4=commerçant	catégorie socio		AC_2	67			
6.26	0.000	59.76	70.00	39.61	C3=fem	sexe		AB_1	82			
6.06	0.000	65.08	58.57	30.43	C6=niveau moyen	Niveau de vie		AD_1	63	-		
3.54	0.000	15.25	12.86	28.50	C6=pauvre	Niveau de vie		AD_2	59			
-3.88	0.000	11.76	8.57	24.64	C4=employé	catégorie socio		AC_3	51			
-3.91	0.000	9.30	5.71	20.77	C6=riche	Niveau de vie		AD_3	43			
-5.11	0.000	0.00	0.00	16.43	C4=ouvrier	catégorie socio		AC_4	34			
-6.26	0.000	16.80	30.00	60.39	C3=masc	sexe		AB_2	125			
-7.03	0.000	0.00	0.00	26.57	C4=cadre	catégorie socio		AC_1	55	--		

CLASSE 2 / 4												

V.TEST	PROBA	----	POURCENTAGES		----	MODALITES		IDEN	POIDS			
CLA/MOD	MOD/CLA	GLOBAL	CARACTERISTIQUES		DES VARIABLES							

28.02 CLASSE 2 / 4										aa2a		58
14.35	0.000	100.00	94.83	26.57	C4=cadre	catégorie socio		AC_1	55			
9.85	0.000	90.70	67.24	20.77	C6=riche	Niveau de vie		AD_3	43			
2.40	0.008	34.40	74.14	60.39	C3=masc	sexe		AB_2	125	-		
2.40	0.008	18.29	25.86	39.61	C3=fem	sexe		AB_1	82			
-4.46	0.000	0.00	0.00	16.43	C4=ouvrier	catégorie socio		AC_4	34			
-5.13	0.000	0.00	0.00	20.29	C6=très pauvre	Niveau de vie		AD_4	42			
-5.55	0.000	4.48	5.17	32.37	C4=commerçant	catégorie socio		AC_2	67			
-5.86	0.000	0.00	0.00	24.64	C4=employé	catégorie socio		AC_3	51			
-6.47	0.000	0.00	0.00	28.50	C6=pauvre	Niveau de vie		AD_2	59	--		

CLASSE 3 / 4												

V.TEST	PROBA	----	POURCENTAGES		----	MODALITES		IDEN	POIDS			
CLA/MOD	MOD/CLA	GLOBAL	CARACTERISTIQUES		DES VARIABLES							

21.74 CLASSE 3 / 4										aa3a		45
13.08	0.000	88.24	100.00	24.64	C4=employé	catégorie socio		AC_3	51			
5.62	0.000	49.15	64.44	28.50	C6=pauvre	Niveau de vie		AD_2	59			
3.93	0.000	40.32	55.56	29.95	C2=prix	Critère		AA_3	62	-		
2.90	0.002	5.00	4.44	19.32	C2=protection	Critère		AA_4	40			
-3.72	0.000	0.00	0.00	16.43	C4=ouvrier	catégorie socio		AC_4	34			
-4.37	0.000	0.00	0.00	20.77	C6=riche	Niveau de vie		AD_3	43			
-4.56	0.000	3.17	4.44	30.43	C6=niveau moyen	Niveau de vie		AD_1	63			
-5.18	0.000	0.00	0.00	26.57	C4=cadre	catégorie socio		AC_1	55			
-5.95	0.000	0.00	0.00	32.37	C4=commerçant	catégorie socio		AC_2	67	--		

CLASSE 4 / 4												

V.TEST	PROBA	----	POURCENTAGES		----	MODALITES		IDEN	POIDS			
CLA/MOD	MOD/CLA	GLOBAL	CARACTERISTIQUES		DES VARIABLES							

16.43 CLASSE 4 / 4										aa4a		34
13.15	0.000	100.00	100.00	16.43	C4=ouvrier	catégorie socio		AC_4	34			
5.75	0.000	27.20	100.00	60.39	C3=masc	sexe		AB_2	125			
4.29	0.000	35.59	61.76	28.50	C6=pauvre	Niveau de vie		AD_2	59	-		
3.60	0.000	0.00	0.00	20.77	C6=riche	Niveau de vie		AD_3	43			
-4.06	0.000	0.00	0.00	24.64	C4=employé	catégorie socio		AC_3	51			
-4.08	0.000	1.59	2.94	30.43	C6=niveau moyen	Niveau de vie		AD_1	63			
-4.29	0.000	0.00	0.00	26.57	C4=cadre	catégorie socio		AC_1	55			
-4.95	0.000	0.00	0.00	32.37	C4=commerçant	catégorie socio		AC_2	67			
-5.75	0.000	0.00	0.00	39.61	C3=fem	sexe		AB_1	82			

Ici encore, on constate que seules les modalités significatives sont représentées (valeurs tests supérieures à 2en valeur absolue). Nous avons réalisé une partition de la population en 4.

1^{ère} classe : Elle contient 33,82% soit le tiers de la population. Pour la modalité *commerçant*, la valeur de CLA/MOD est de 95,52%. Ce qui est la proportion des individus de la classe qui sont des commerçants. C'est donc par essence la classe des commerçants. Près de 60% de femmes sont dans cette classe (CLA/MOD = 59,76) et la population de cette classe est à 70% féminine (MOD/CLA = 70) (ce qui confirme par ailleurs l'association femme et commerçant dans le plan factoriel dans l'exemple de l'ACM). C'est donc la classe des commerçants, dominée par les femmes.

2^{ème} classe : elle contient 28,02% de la population. Tous les cadres y sont (CLA/MOD = 100) et y dominent (MOD/CLA = 94,83). Au ¾, ce sont des hommes car la modalité masc a un MOD/CLA = 74,14). Plus de 90% des riches se retrouvent dans cette classe et constituent les 2/3 de la classe (CLA/MOD = 90,70 et MOD/CLA = 67,24). C'est donc la classe des cadres, qui sont riches, et généralement des hommes.

Le lecteur en poursuivant les commentaires constatera que la 3^{ème} classe est celle des employés, aux 2/3 pauvres, et la 4^{ème} classe constitué totalement d'hommes, ouvriers, et aux 2/3 pauvres.

En résumé, le meilleur critère discriminant est la catégorie socioprofessionnelle.

Solution Exercice chapitre 2

- 1) $N(I) = \{(100\ 000, 90\ 000, 5, 1) ; (150\ 000, 125\ 000, 3, 7) ; (160\ 000, 95\ 000, 2, 3) ; (70\ 000, 58\ 000, 6, 10)\}$.
- 2) L'inertie totale est la somme des variances. Nous présentons une méthode de calcul de la variance d'une variable à au travers d'un tableau :

On calcule la somme des X_i et en divisant par N on obtient la moyenne qu'on élève au carré (1). Puis, on calcule la somme des X_i^2 que l'on divise aussi par N , on obtient la moyenne des carrés (2). La différence (2) – (1) nous donne la variance. Ci-dessous, nous avons un exemple illustratif avec la variable revenu.

Individu	Revenu : X (x 1000)	X^2 (x 1000 000)
1	100	10000
2	150	22500
3	160	25600
4	70	4900
Somme	480	63000
(Somme/N) ²	14400 (1)	15750 (2)

Le tableau suivant récapitule les résultats (moyennes et variances).

L'inertie totale (somme des variances) de la variable revenu est de : $I = 1350 \times 10^6$.

- 3) On trouve $d(e_1, e_2) = 61\ 032$; $d(e_2, e_3) = 31\ 622$. On constate que e_1 est pratiquement à une double distance de e_2 que e_3 .

	Variables butes				Variables centrées réduites			
Individu	Revenu (x 1000)	Dépenses de consommation (x 1000)	Taille ménage	Expérience prof. (en années)	Revenu	Dép. cons.	Taille	Expéri. prof.
1	100	90	5	1	-0,54433	-0,00008	0,63246	-1,21740
2	150	125	3	7	0,81650	0,00132	-0,63246	0,50128
3	160	95	2	3	1,08866	0,00012	-1,26491	-0,64450
4	70	58	6	10	-1,36083	2,30985	1,26491	1,36062
Moyenne	120	92	4	5,25	0	0	0	0
Ecart type	36,7	24,0	1,6	3,5	1	1	1	1

- 4) Le tableau qui précède présente les valeurs centrées réduites des différentes variables.
- 5) On observe que toutes les variances sont égales à 1.
- 6) Les nouvelles distances sont : $d(e_1, e_2) = 2,53$; $d(e_2, e_3) = 1,34$. Ici, e_1 est à une distance de e_2 1,8 fois supérieure à celle de e_3 . on constate que le fait de centrer et réduire les données modifie les rapports de distances. En fait, lorsque les variables ne sont pas centrées et réduites, les rapports de distances sont grandement influencés par les variables de grande échelle, ou qui ont des grandes valeurs.

LECTURES CONSEILLEES

Bouroche J-M. et Saprota G. (1998), *L'analyse des données*. Collection « Que sais-je » PUF.

Bry X. (1995 a), *Analyse factorielle simple*. Economica.

(1995b), *Analyse factorielle multiple*. Economica.

De Lagarde J. (1998), *Initiation à l'analyse factorielle*. Dunod, Paris. Escofier

B. et Pagès J. (1988), *Analyses factorielles simple et multiple*. Dunod Foucart

T. (1997), *L'analyse des données, mode d'emploi*. PUR, Rennes.

Lebart L., Morineau A. et Piron M. (1995), *Statistique exploratoire multidimensionnelle*. Dunod.

Les cahiers Morineau A. et Morin St. (2000), *Pratique du traitement des enquêtes*, CISIACERESTA, Paris.

Saporta G. (1989), *Probabilité, analyse des données et statistiques*. Technip.

Saporta G. (1990) *Analyse des Données*, ENSAE.

Tenenhaus M. (1994), *Méthodes statistiques en gestion*. Dunod. Volle

M. (1985), *Analyse des données*. Economica.

De la collection des cahiers de l'ENSEA (de Bry Xavier)

- Analyse factorielle simple
- Introduction à l'analyse des correspondances
- Introduction à l'analyse en composantes principales
- Introduction à l'analyse factorielle et à la classification